

مقدمه ای بر یادگیری ماشین

سولویگ بدیلو^{*}, +، بالاژ بنفای[†], فایبیان بیرزله[‡], لوسی هاچینسون[§], تونی کام-تونگ^{||}, جولیان سیپور-پولسترا^{||}, برنهارد استیرت[†], وجیتاو و دیوید ژانگ[†]

در چند سال گذشته، یادگیری ماشین (ML) و هوش مصنوعی موج جدیدی از تبلیغات را به خود دیده اند که ناشی از حجم عظیم و روزافزون داده ها و قدرت محاسباتی و همچنین کشف الگوریتم های یادگیری بهبود یافته است. با این حال، ایده یادگیری مفاهیم انتزاعی از داده ها توسط کامپیوتر و اعمال آنها در موقعیت های ناشناخته، چیز جدیدی نیست و حداقل از دهه 1950 وجود داشته است. بسیاری از این اصول اساسی برای جامعه فارماکومتریک و فارماکولوژی بالینی بسیار آشنا هستند. در این مقاله، من خواهیم ایده های اساسی یادگیری ماشین را به این جامعه معرفی کنیم تا خوانندگان ابزارهای ضروری مورد نیاز برای درک انتشارات مربوط به این موضوع را به دست آورند. اگرچه ما به جزئیات و پیشینه نظری خواهیم پرداخت، اما هدف ما این است که خوانندگان را به ادبیات مربوطه ارجاع دهیم و کاربردهای یادگیری ماشین را در زیست شناسی مولکولی و همچنین زمینه های فارماکومتریک و فارماکولوژی بالینی در چشم انداز قرار دهیم.

تعاملات. این پیچیدگی می تواند چالش هایی را برای تفسیر مدل ایجاد کند (به اصطلاح مشکل، "جعبه سیاه"). رویکردهای که معمولاً در کاربردهای فارماکومتری استفاده می شوند، در فرهنگ اقرار می گیرند، که در آن یک مدل اساسی بر اساس اصول دارویی و درک خواص دارو فرض می شود. چنین مدل هایی معمولاً از نظر فیزیولوژیکی قابل تفسیر هستند. اگر رویکردهای یادگیری ماشین (ML) در فرهنگ ۲ قرار می گیرند، که در آن هیچ مدل صریح مشخص نشده است و یک کامپیوترمسئول شناسایی ارتباطات در داده های مشاهده شده است. تفسیر این مدل ها از نظر فیزیولوژیکی دشوار است، با این حال، در طول سال های پیشرفت قابل توجهی در تفسیرپذیری مدل های ML حاصل شده است.^۷. اما روزه، بسیاری از جنبه های یک مدل جعبه سیاه را می توان با استفاده از ابزارهای مناسب تفسیر کرد.^۸ در این مقاله، هدف ما پیشتبانی از خوانندگان برای توسعه شهود مورد نیاز برای درک چگونگی یادگیری کامپیوتراها یا کمک به انسان ها در شناسایی الگوهای در داده ها است. ایده های بنیادی یادگیری ماشین بر جسته شده اند، اما جزئیات و پیشینه نظری روش های یادگیری ماشین موجود را شرح نمی دهیم. خوانندگان علاقه مند را به مقالات یا کتاب های دیگر، مانند «عناصر یادگیری آماری» ارجاع می دهیم.^۹ که به عنوان ESL شناخته می شود) و ما به نمونه های از کاربرد آنها در زیست شناسی مولکولی، کشف دارو، توسعه دارو و داروشناسی بالینی اشاره می کنیم.

مالتنا دمایهای نقاط داده، ویژگی ها، فضاهای ویژگی و معیارهای شباهت را معرفی می کنیم و سپس عمیق تر به دو حوزه اصلی یادگیری ماشین، یعنی یادگیری بدون نظارت و یادگیری تحت نظارت، می پردازم و جنبه های کلیدی و مثال ها را بررسی می کنیم. در مورد یادگیری بدون نظارت، کامپیوتراها وظیفه دارند یاد بگیرند که چگونه کلاس با مقدار نقاط نظارت، کامپیوتراها مشاهده شده را بر اساس یک مفهوم (که اغلب "مدل" نیز نامیده داده هنوز مشاهده داده آموزشی استخراج شده است، پیش بینی کنند. **شکل ۱** اطیقه بندی روش های مختلف شرح داده شده در این مقاله را نشان می دهد و من تواند

ظهور دسترسی به داده ها و رشد قدرت محاسباتی، همراه با ورود روش های نوین یادگیری، منجر به پیشرفت های چشمگیری در بسیاری از حوزه های علمی شده است. این شامل تحقیقات بیولوژیکی و بالینی می شود که کاربردهای آن از زیست شناسی مولکولی گرفته تا ... ابرای مفاهیم انتزاعی توسط کامپیوترا - بالینی.^{۱۰} با این حال، ایده یادگیری مفاهیم انتزاعی توسط کامپیوترا - مانند کاری که انسان ها دایمآماً انجام می دهند - حداقل از دهه ۱۹۵۰، زمانی که اولین شبکه های عصبی ساخته شدند، وجود داشته است.^{۱۱} توسعه داده شدند. حتی قبل از آن، روش های دیگری مانند آمار بیزی وزنگیره های مارکوف با ایده ای مشابه مورد استفاده قرار می گرفتند. بسیاری از این روش ها با قراردادهای نامگذاری مختلف برای جامعه فارماکومتریک و فارماکولوژی بالینی شناخته شده اند. در سمت چپ، اصطلاحات یادگیری مفهومی ماشین و در سمت راست، نامگذاری معمول آمار (بر اساس <https://statweb.stanford.edu/~tibs/stat315a/glossary.pdf>) Tibshirani <https://statweb.stanford.edu> را نشان می دهیم:

- شبکه، نمودارها ↔ مدل
- وزنه ها ↔ پارامترها
- یادگیری ↔ مناسب سازی
- تعمیم ↔ عملکرد مجموعه آزمون
- یادگیری تحت نظارت ↔ رگرسیون یا طبقه بندی
- یادگیری بدون نظارت ↔ تخمین چگالی، خوش بندی
- ویژگی ها ↔ متغیرهای کمک یا نویضیح

تفاوت اصلی با رویکردهای سنتی تر، تا حد زیادی در دو فرهنگ متمایز مدل سازی آماری نهفته است. برین تقریباً دو دهه پیش از این موضوع طفره رفته بود. در اینجا، ما تعریف او را با گنجاندن مدل های فیزیولوژیکی در یکی از فرهنگ ها گسترش می دهیم. به طور خاص، فرهنگ ۲ شامل تعیین مدل برای توصیف داده های مشاهده شده است و فرهنگ ۱ اتخاذ یک رویکرد مدل سازی الگوریتمی، قصد دارد مسئله را حل کند، بنابراین ذاتاً منجر به مدل هایی با تعداد بیشتری از پارامترهای آزاد و پیچیدگی های بیشتر می شود.

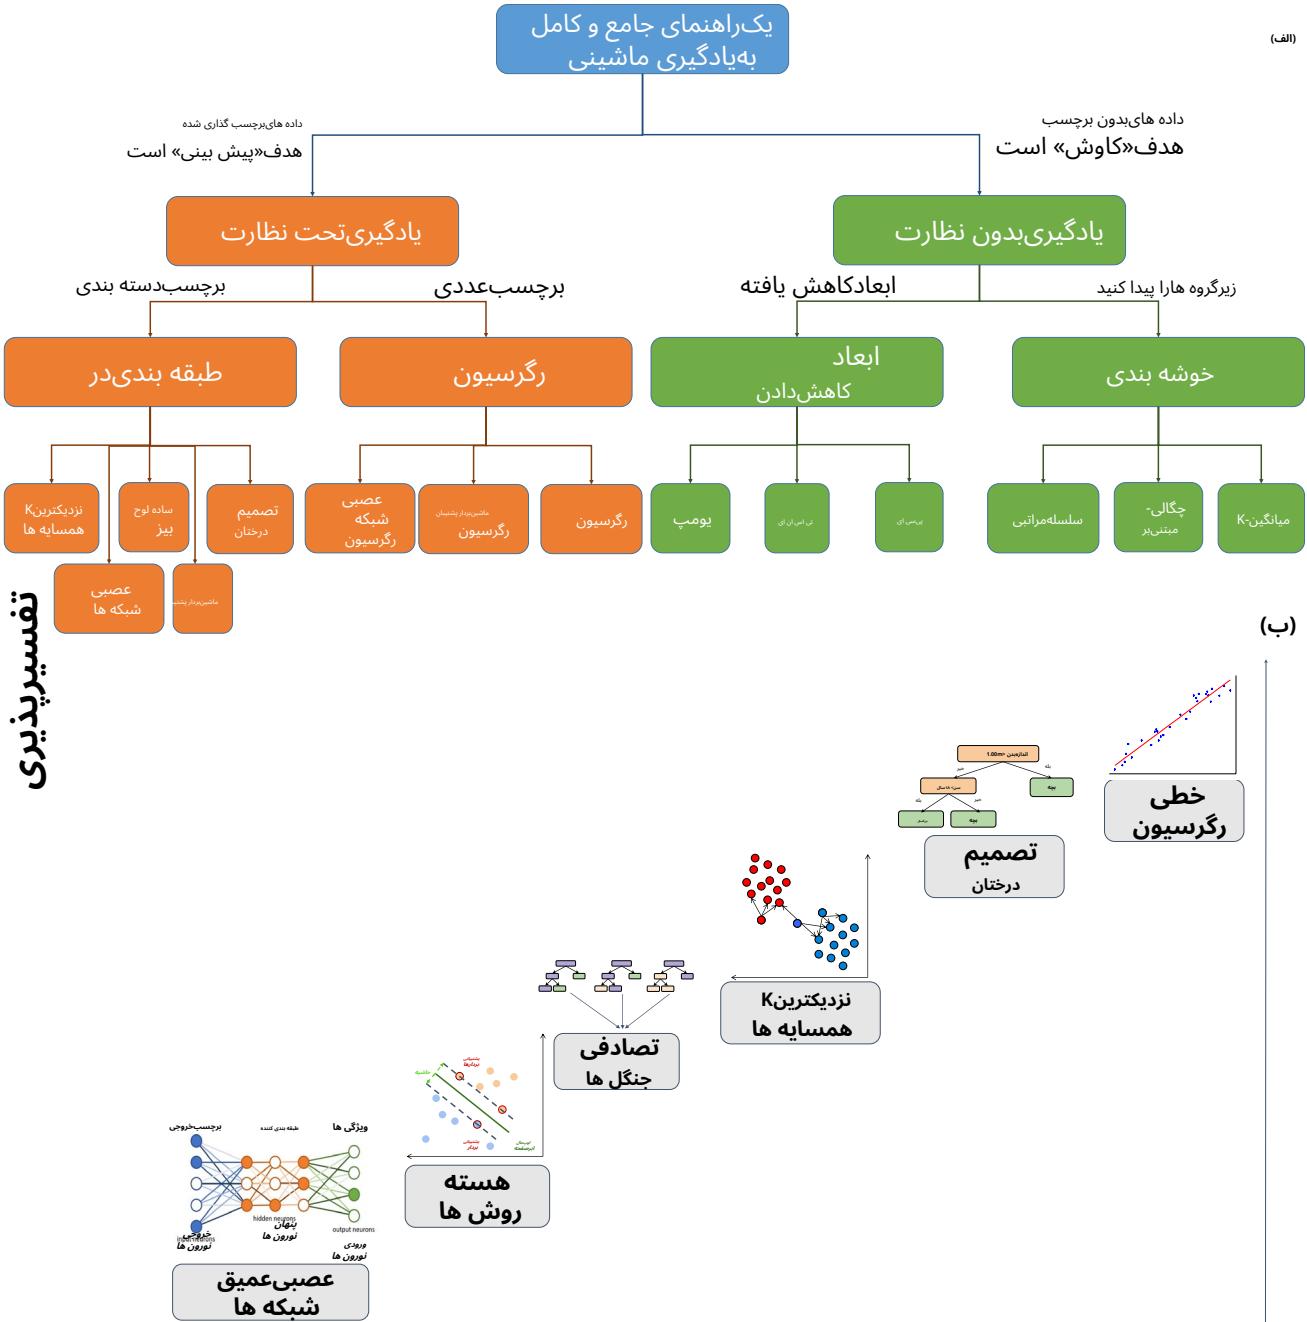
* اعلومن دارویی، تحقیقات و توسعه اولیه داروسازی روش (pRED)، مرکز نوآوری روش بازیل، بازیل، سوئیس.

[†] مکاتبه: Solveig Badillo (solveig.badillo@roche.com) نویسنده کان به ترتیب حروف الفبا. همه نویسنده کان به طور مساوی مشارکت داشتند.

[اصلاحیه در تاریخ ۶ مارس ۲۰۲۰، پس از اولین انتشار آلتاین اضافه شد: متن مشارکت نویسنده اضافه شد].

آنس.ب. در زمان نگارش این دست نوشتہ، در استخدام گروه سولادیس بود.

دربافت شده در ۸ اکتبر ۲۰۱۹؛ پذیرفته شده در ۱۵ ژانویه ۲۰۲۰. doi:10.1002/cpt.1796.



عملکرد

شکل اطیقه بنده و مرور کلی الگوریتم های اصلی یادگیری ماشین (ML)،(الف)طبقه بندي روش های مختلف ارائه شده، (ب)مروری بر روش های یادگیری ماشین. طیف روش های موجود از ساده تر و فرسیریدنی تر تا الگوریتم های پیشرفته تر با عملکرد بالقوه با الترا به قیمت تفسیرپذیری کمتر، متغیر است. موقعیت روش ها روی شکل یکی است و در عمل به تعداد پارامترهای آزاد، بیچیدگی مدل، نوع داده و تعريف دقیق تفسیرپذیری مورد استفاده بستگی دارد. تقریب و تصویر منیفولد یکنواخت، UMAP، tSNE، PCA، SVM، تحلیل مؤلفه های اصلی؛ همسایه تصادفی، توزع شده با

نقدهای داده، موجودیت را نشان می‌دهد که می‌خواهیم آن را تجزیه و تحلیل کنیم. بنابراین، یک نقطه داده می‌تواند هر چیزی مانند یک بیمار یا نمونه‌ای که از بافت سلطانی گرفته شده است را نشان دهد. بسیاری از مسائل مربوط به داده‌ها، جهان‌هستند و نه تنها بر روی کردهای یادگیری ماشین، بلکه بر هر رشته کمی، از جمله فارماکومتری، تأثیر می‌گذارند.

برای گردآوری مجموعه داده‌ها، تعدادی از ویژگی‌ها (یعنی داده‌هایی که ویژگی‌ها، داده‌ها را توصیف می‌کنند) اندازه‌گیری و جمع‌آوری، شده‌اند.

به عنوان مرجعی، هرچند غیرجامع، در مورد اینکه چه سنتاریویی برای استفاده از کدام ابزار یادگیری ماشین مناسب است، استفاده می شود. لطفاً توجه داشته باشید که تمام روش های یاد نهاده شده، نتایجی را که بحسب ها داده اند، باشند نمی باشند. احتمال است تا در نظر گرفتن این محدودیت ها، نتایجی که در این مقاله ارائه شده اند، ممکن است نتایجی دیگری را نشان دهند.

داده ها و پیزگ ها در یادگیری ماشین، ما با داده ها و مجموعه داده ها سروکار داریم. یک مجموعه داده از چندین نقطه داده (که گاه نامنه نباید م، شوند) تشکیل شده است، که در آن هر

میانگین ویژگی در تمام نمونه هایی که در آنها تعریف شده است، با این حال، این گاهی اوقات می تواند باعث بیش برآش شود^{۱۰} (همچنین به بخش «معیارهای عملکرد و مسئیله بیش برآش» مراجعه کنید).

همچنین بررسی دقیق هرگونه سوگیری در داده ها (مثلًاً سوگیری انتخاب) ضروری است. ترجیحاً، نمونه های ML باید یک زیرمجموعه تصادفی بدون سوگیری از جمعیت باشند. در عمل، این امر به ندرت اتفاق می افتد و برعکس سوگیری ها در داده ها وجود دارد. این سوگیری هامی توانند بر توانایی مدل برای تعیین فراتر از مجموعه داده های آموزشی (و حتی مجموعه داده های آزمایشی) اگر هر دو سوگیری مشابه داشته باشند) تأثیر بگذارند. نمونه ای از چنین مسئیله تعیینی، مدلی است که قرار است یاد بگیرد چگونه گرگ را از هاسکی بر اساس ویژگی های حیوان تشخیص دهد، اما در نهایت معلوم می شود که به سادگی تکه های برف را روی عکس تشخیص من دهد. گروکردهای مختلف برای کاهش سوگیری وجود دارد (مثلًاً من توان نمونه ها یا ویژگی های سوگیرانه را کم وزن کرد یا به طور کامل حذف کرد).^{۱۱} به طور خاص، نمرات گرایش هنگام تخمین اثر یک مداخله درمانی مفید هستند.^{۱۲} بررسی اهمیت ویژگی، اطلاعات ارزشمندی در مورد بزرگ و تأثیر بایاس ارائه می دهد.^{۱۳} که توصیه های شود برای بررسی قابلیت اعتماد مدل های یادگیری ماشین استفاده شود.

بسیاری از مجموعه داده های طبقه بنده بالینی نامتوازن هستند، به این معنی که یک یا چند کلاس کمتر از حد واقعی نمایش داده اند. این می تواند برای سیاری از الگوریتم های یادگیری ماشین، از جمله شبکه های عصبی مصنوعی و روش های تقویت گرایان، مشکلاتی ایجاد کند. یک راه برای کاهش این مشکل، نمونه گیری کمتر/بیش از حد به ترتیب از کلاس اکثریت/اقلیت، یا تنظیم هزینه طبقه بنده نادرست در تابع هدف است.^{۱۴} در نهایت، برای سیاری از کاربردها، تعریف یک معیار شباهت یا فاصله بین دو نقطه داده در فضای ویژگی مهم است. ساده ترین معیار فاصله، فاصله اقلیدسی است:

$$(1) \quad \text{فاصله اقلیدسی} = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

بین بردارهای ویژگی عددی دو نقطه داده /الف و ب، برای ویژگی ها = ۱... ن، اما بسته به نوع داده ای که با آن سروکار داریم، می تواند معیارهای فاصله یا شباهت بسیار پیچیده تری مانند شباهت کسینوس وجود داشته باشد.^{۱۵}

یا ماتیازهای شباهت دو توالی بیولوژیکی.

غذاهای اصلی
• تبدیل داده های ورودی و مهندسی ویژگی ها ممکن است مدل را بهبود بخشد.

• داده های گمشده نیاز به جانه دارند.

• سوگیری های موجود در داده ها باید به دقت بررسی شوند.

• مجموعه داده های نامتوازن نیاز به اصلاح مدل دارند.

• معیارهای معنادار شباهت بین نمونه ها باید تعریف شوند.

یادگیری بدون نظارت در تحلیل اکتشافی داده ها، ما اغلب «برچسب های» واقعی را نمی دانیم، یا ممکن است بخواهیم الگوهای طبیعی در حال ظهور در داده هارا بررسی کنیم. برای این منظور، می توانیم از روش های یادگیری بدون نظارت، مانند خوشه بنده، تشخیص الگوهای مکرر و کاهش ابعاد استفاده کنیم. در اینجا، ما به طور خاص تمرکز خواهیم کرد.

امتیاز. این ویژگی ها می توانند دسته بندی شده (مقادیر از پیش تعریف شده) دون ترتیب خاص مانند مرد و زن، ترتیبی (مقادیر از پیش تعریف شده که دارای ترتیب ذاتی مانند مرحله بیماری هستند) یا عددی (مثلًاً مقادیر واقعی) باشند. برای یک بیمار در یک محیط بالینی، این ویژگی ها می توانند (ترکیبی از) اطلاعات جمعیت شناختی بیمار، سابقه بیماری، نتایج آزمایش خون یا معیارهای پیچیده تر و با ابعاد بالا، مانند پروفایل های بیان ژن در یک بافت خاص یا تمام پلی مورفیسم های تک نوکائوتیدی که نشان دهنده ثنومن منحصر به فرد بیمار هستند، باشند.

هر ویژگی، یک بعد از فضای ویژگی را نشان می دهد و مقدار مشخص یک ویژگی برای یک نقطه داده خاص، آن نقطه را در مکانی تعریف شده این بعد از فضا قرار می دهد. در مجموع، تمام مقادیر تمام ویژگی های یک نقطه داده، بردار ویژگی نامیده می شود. هرچه ویژگی های بیشتری برای مجموعه داده ها جمع آوری کرده باشیم، بردار ویژگی حاصل و فضای ویژگی، ابعاد بالاتری خواهد داشت. بدیهی است که با افزایش ابعاد، تجسم تمام ابعاد فضای ویژگی، دشوار می شود و ما باید برای شناسایی الگوهای مربوطه به کامپیوتر تکیه کنیم یا از روش های کاهش ابعاد استفاده کنیم، همانطور که بعداً در بخش «کاهش ابعاد» توضیح داده خواهد شد.

داروشناسان بالینی معمولاً با داده های طولی، مانند پروفایل های فارماکوکنیتیک (PK) و فارماکو دینامیک (PD)، که در آن ها وابستگی به زمان نقش محوری دارد، آشنا هستند. در واقع، مدل های مورد استفاده در فارماکو متري مبتنی بر معادلاتی هستند که می توانند بر اساس فیزیولوژی و فارماکولوژی توجیه شوند و بینش های در مورد تکامل زمانی سیستم ارائه دهند. این امر، به عنوان مثال، مشابه مسایل فیزیکی مانند پیش بینی آب و هوای این جریان هوا و دما منجر به رفتار زمانی خاصی از سیستم می شوند. در یادگیری ماشین، گنجاندن زمان به عنوان یک متغیر پیوسته تمایز در الگوریتم های مربوطه، همچنان چالش برانگیز است و حوزه ای از تحقیقات فعلی است. در حال حاضر، چندین گزینه برای گنجاندن داده های وابسته به زمان در مجموعه داده های یادگیری ماشین وجود دارد: یا به طور مستقیم که در آن هر نقطه زمانی نشان دهنده یک ویژگی است، یا از طریق تبدیلات مانند تبدیل فوریه یا B-splines که منجر به ضرایب توابع اساسی می شود که می توانند به عنوان ویژگی در نظر گرفته شوند. از طرف دیگر، شبکه های عصبی بازگشتشی (RNN) می توانند برای مدیریت داده های طولی، همانطور که در بخش "شبکه عصبی بازگشتشی" ذکر شده است، استفاده شوند. با این حال، همه این روشکردها محدودیت های سازی بعد زمانی - چه مستقیم و چه غیرمستقیم - را دارند.

اکثر الگوریتم های یادگیری ماشین برای مدیریت مجموعه داده های با ابعاد بالاطراحتی شده اند. از این رو، ویژگی های مشتق شده از داده های موجود اغلب شامل می شوند، مانند داده های تبدیل شده با لگاریتم، حاصلضرب ها و نسبت های ویژگی های یا ترکیبات پیشرفتی تر، چنین تبدیل داده ای یک مرحله پیش پردازش مهم است که می تواند تأثیر عمیق بر عملکرد مدل داشته باشد. بنابراین، همیشه ایده خوبی است که از داشن و تخصص موجود در جوزه برای دستیابی به ویژگی های مرتبط استفاده شود، فرآیندی که گاهی اوقات به عنوان مهندسی ویژگی شناخته می شود.

کیفیت داده ها نقش حیاتی در یادگیری ماشینی ایفا می کند. روش های یادگیری ماشینی که با دقت انتخاب شده اند و بازرسی بصیری، از مقادیر شدیدی داده های پر ت جلوگیری می کنند. همه روش ها از داده های گمشده پشتیبانی می توانند چالش برانگیز باشند. همه روش ها از داده های گمشده پشتیبانی نمی کنند و در چنین مواردی، تبدیل داده ها می توانند به عنوان یک مرحله پیش پردازش مورد نیاز باشند. روش های می توانند به عنوان یک مرحله گمشده وجود دارد که عملکرد آنها به مجموعه داده ها و روش مورد استفاده باشند. بدیهی ترین روشی که یادگیری جایگزینی یک مقدار گمشده با

شناسایی خوشه های معنادار، که می تواند به ویژه با توجه به فضای ویژگی با ابعاد بالا چالش برانگیز باشد.

گروه دیگری از روش های خوشه بندی، خوشه بندی مبتنی بر چگالی است.^{۱۹} این روش های مبتنی بر چگالی، یک خوشه بخش از فضای ویژگی را نشان می دهد که در آن نقاط داده متراکم هستند. نقاط داده متعلقی به میان طبقه ای خوشه بندی مبتنی بر چگالی کم، نویز در نظر گرفته می شوند. یک انتخابی خوشه بندی چگالی بازگاری نویز است.^{۲۰} خوشه بندی مبتنی بر چگالی نیازی به مقدار از پیش تعريف شده ای برای تعیین تعداد خوشه ها ندارد و نتیجه ای تکرار پذیر ارایه می دهد. علاوه بر این، قادر به شناسایی اشکال پیچیده خوشه ها، مانند آنچه در شکل نشان داده شده است، نیز می باشد.

شکل ۲

در تحلیل خوشه بندی سلسله مراتبی، هدف ساخت سلسله مراتبی از خوشه هاست (ESL)، فصل ۱۴.^{۲۱} یک رویکرد ساده برای خوشه بندی سلسله مراتبی، اتصال همسایه است. ابتدا، تمام فواصل جفنی بین تمام نقاط داده در مجموعه داده ها محاسبه می شوند. سپس، در هر مرحله از یک فرآیند تکراری، دو نقطه داده با کمترین فاصله با هم گروه بندی می شوند. این منجر به یک ساختار خوشه بندی درخت مانند می شود، همانطور که در شکل نشان داده شده است. **شکل ۲ الف** سمت چپ و بالای نقشه حرارتی که طول شاخه های درخت نشان دهنده فواصل نمونه ها است. برای رسیدن به مجموعه ای گستره از خوشه ها مانند که یک آستانه فاصله انتخاب شودکه در آن درخت به صورت افقی بریده شود. باز هم، هیچ راه بهینه ای برای انتخاب چنین آستانه ای وجود ندارد و ممکن است راه حل های معقول زیادی وجود داشته باشد. خوشه بندی سلسله مراتبی می تواند به تهایی یا در ترکیب با نقشه های حرارتی (مثل **شکل ۲ الف**) برای تجسم ویژگی های انتخاب شده یا همه آنها، به عنوان مثال، داده های بیان ژن.

کاهش ابعاد

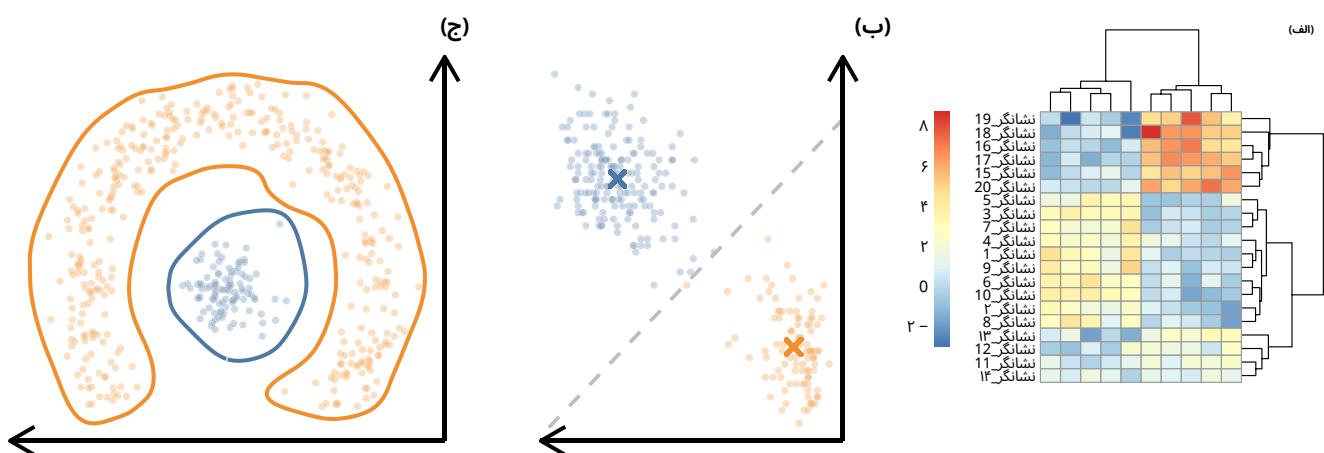
تعداد ویژگی ها و بنابراین، ابعاد فضای ویژگی می تواند بسیار زیاد باشد و داده ها هزار معیار در هر نمونه داشته باشد. این امر نه تنها تجزیم داده ها را چالش برانگیز می کند، بلکه تجزیه و تحلیل آنها را نیز چالش برانگیز می کند. به طور خاص، تجزیه و تحلیل مجموعه داده های با ابعاد بالا می تواند با پدیده ای به نام «نفرین ابعاد» مرتبط باشد.^{۲۲} که به پراکندگی داده ها و ویژگی های هندسی غیرشوهودی در داده های با ابعاد بالا اشاره دارد

در مورد خوشه بندی و کاهش ابعاد، زیرا کاربردهای زیادی در زیست شناسی مولکولی و عمل بالینی دارند.

خوشه بندی هدف از کارگیری روش های خوشه بندی، شناسایی زیرگروه های مرتبط در یک مجموعه داده معین بدون داشتن فرضیه ای از پیش تعريف شده در مورد ویژگی هایی است که زیرگروه ها ممکن است داشته باشند. به عنوان مثال، در گروهی از بیماران مبتلا به یک بیماری خاص، ممکن است بخواهیم زیرگروه هایی را شناسایی کنیم که نشان دهنده مکانیسم های بیولوژیکی متمایزی هستند که بیماری را بر اساس اقدامات مولکولی انجام شده دایت می کنند.^{۲۳}

یک خوشه زیرمجموعه ای از داده ها است که به یکدیگر « شبیه » هستند، در حالی که نقاط متعلق به خوشه های مختلف « متفاوت » هستند. رویکردهای متعددی برای خوشه بندی وجود دارد که از الگوریتم های اساسی مختلفی برای گروه بندی نقاط داده بر اساس « شباهت » آنها استفاده می کنند. همه آنها مزایا و معایب دارند و بسته به کاربرد و ویژگی های داده ها، باید با دقت انتخاب شوند.

یک رویکرد ساده برای خوشه بندی که معنی خوشه بندی است.^{۲۴} اینجا، تعداد خوشه هایی که باید شناسایی شوند، توسط یک مرکز خوشه نمایش کاربرای پیش تعريف شده است. که هر خوشه توسط یک مرکز دهنده میانگین (یا میانه) مقدار تمام نقاط اختصاص داده شده به این خوشه است. در این داده های مراکز خوشه، که به عنوان "دانه ها" شناخته می شوند، به طور تصادفی در فضای ویژگی قرار می گیرند. سپس الگوریتم دو مرحله را تکرار می کند. در مرحله اول ("انتساب")، نقاط داده به خوشه ای که توسط نزدیکترین مرکز نشان داده شده است، اختصاص داده می شوند. در مرحله دوم ("تغییر مرکز")، موقعیت هر مرکز خوشه بر اساس ترکیب خوشه ها پس از مرحله اول به روز می شود. پس از تعدادی تکرار، این معمولاً به یک بهینه محلی همگرا می شودکه در آن انتساب خوشه ها تغییر نمی کند یا فقط به میزان کمی تغییر می کند. نتیجه چنین فرآیندی در شکل نشان داده شده است. **شکل ۲ ب** با گچه این روش شهودی است، اما اشکال اصلی آن این است که معمولاً خوشه بندی به شدت تحت تأثیر مقدار ... قرار می گیرد. و اغلب تعداد واقعی خوشه ها در داده ها ناشناخته است به طور پیشینی از آنجا که در خوشه بندی به ندرت یک پاسخ درست یا غلط قطعی وجود دارد، بررسی بیشتر خوشه بندی برای



شکل ۲ امروری بر نتایج رویکردهای مختلف خوشه بندی. (الف) نتایج یک خوشه بندی دوبعدی را نشان می دهد. دو دندروگرام، شباهت بین نمونه ها و همچنین بین نشانگرهای اندازه گیری شده را تجسم می کنند. چنین تجسمی در زیست شناسی اغلب در فناوری omics-^{۲۵} استفاده می شود. (ب) نتایج یک خوشه بندی کلاسیک را با استفاده از نشان می دهد که یعنی با مقدار انتخابی ۲=۲. خوشه های حاصل معمولاً محدود هستند و هر نقطه به یک خوشه اختصاص داده می شود. یعنی خوشه ای که با نزدیکترین نقطه مرکزی (با X مشخص شده است) نشان داده شده است. (ج) نتایج خوشه بندی مخصوص شده است (نشان داده شده) نشان داده شده است. لطفاً توجه داشته باشید که این رویکرد می تواند اشکال خوشه های غیرمحدود، مانند خوشه نارنجی، را شناسایی کند.

خروجی برای داده های جدید دیده نشده، که در آن مقادیر ورودی را مشاهده کرده ایم اما خروجی مرتبط با آنها را ندیده ایم.
دوسته اصلی از یادگیری ناظارت شده وجود دارد: (۱) طبقه بنده که در آن مقادیر خروجی به صورت دسته بنده هستند، و (۲) رگرسیون که در آن مقادیر خروجی به صورت عددی هستند.

در بخش های بعدی، زمینه برآش مدل در یادگیری ناظارت شده و مسئله رایج بیش برآش معرفی می شوند. سپس، توضیح من دهیم که چگونه عملکرد برای ابزارهای طبقه بنده و رگرسیون ارزیابی می شود (یعنی چگونه کیفیت نگاشت از ورودی ها به خروجی هاتوسط الگوریتم ارزیابی شود). این جنبه ضروری است، زیرا مزیت اتخاذ روش های یادگیری ماشین اغلب حول محور دستیابی به عملکرد بالاترا بده بستان تفسیرپذیری متمنک است. درک معیارهای مختلف عملکرد، ارزیابی بهتر مزایای یک مدل پیشنهادی را امکان پذیرم کند، برخلاف این فرض که یک راه حل یادگیری ماشین همیشه می تواند از یک رویکرد سنتی بهتر عمل کند.

سپس به بررسی برخی از روش های طبقه بنده و رگرسیون موجود می پردازم، از سطح پایین شروع می کنیم، جایی که تفسیر مدل ها هنوز سرراست است، و به سمت رویکردهای یادگیری ماشین رفته تفسیریش می رویم که در آن ها عملکرد، اغلب به قیمت از دست از نظر عملکرد و قابلیت تفسیر خلاصه می کند. این بخش با مروری نه چندان جامع بر کاربردهای روش های یادگیری ناظارت شده در زیست شناسی و به ویژه داروشناسی بالینی به پایان می رسد.

معیارهای عملکرد و مسئله ای بیش برآش
هدفیک الگوریتم یادگیری، یادگیری یک مفهوم با تابع (= یک مدل) است که داده های آموزش مشاهده شده را توصیف می کند و قادر است با اختناب از کم برآش (underfitting) و بیش برآش (overfitting) مستقل جدید تعمید کند.

عملکردیک مدل با روش هایی ارزیابی می شود که امکان ارزیابی مدل را فراهم می کند (یعنی تخمین میزان عملکرد کلی یک مدل مشخص و انتخاب مدل؛ و تخمین عملکرد مدل های مختلف برای انتخاب مناسب ترین مدل). برخی از این روش ها در بخش های بعدی بر جسته شده اند.

برآش مدل پارامترهای مدل بر اساس داده های مشاهده شده در مجموعه آموزشی تخمین زده می شوند. برای استخراج مقادیر بهینه پارامترها (مثلًا برای ضرایب و وزن ها)، یک معیار فاصله بین مدل و داده هاتعریف و به صورت عددی کمینه می شود. مستقل از معیار انتخاب شده، هدف از برآش مدل همیشه تخمین پارامترها با کمینه کردن فاصله است که به آن فاصله نیز گفته می شود. تابع زیان یا تابع هزینه، با دو الزام:

- مدل باید مقادیر پیش بینی شده ای را ارائه دهد که به مقادیر مشاهده شده در مجموعه آموزش نزدیک باشند، در غیر این صورت می گوییم که برآش ها و از درجه بالایی برخوردار است تعصب.
- مدل باید فراتر از مجموعه آموزش خوب پیش بینی می کند اما روی یک مجموعه آزمون مستقل ضعیف است، اغلب به این دلیل که برای داده ها خیلی پیچیده است. در این مورد، ما همچنین در موردواریانس بالا.

در ادامه، تماس خواهیم گرفت تابع هدف هر تابعی که برای تخمین پارامترهای مدل بهینه شده باشد.

فضاهای «نفرین ابعاد» چالش هایی را در اکثر رویکردهای تحلیل داده ها، از جمله یادگیری ماشین (ML) ایجاد می کند، اما محدود به آنها نیست.

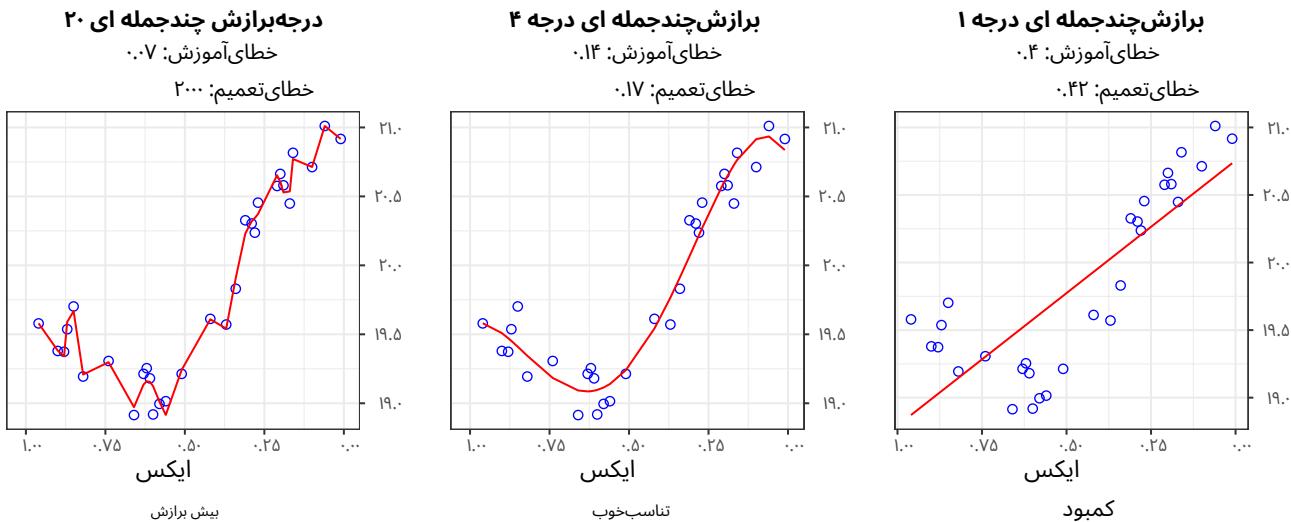
برای کاهش چنین مشکلاتی، می توان از روش های کاهش ابعاد استفاده کرد. کاهش ابعاد می تواند با تبدیل هر نقطه داده با ابعاد بالا بهدو یا چند بعد، ضمن حفظ اکثر تغییرات و فواصل نسبی، به تجسم داده ها کمک کند. علاوه بر این، حذف ویژگی های غیرمفید می تواند عملکرد مدل و زمان همگرایی را بهبود بخشد. اگرچه برخی از این روش ها، مانند تحلیل مؤلفه های اصلی، مدت ها قبل از ابداع اصطلاح یادگیری ماشین توسعه یافته اند، ۲۰۰۰ موارد دیگر، مانند جاسازی همسایه تصادفی توزیع شده با ۲۳۴ تا ۲۴۱ توسعه یافته اند و به چالش های پیچیده ای که در تجزیه و تحلیل داده ها ایجاد می شوند، می پردازند. همچنین یک رویکرددترمند کاهش ابعاد مبتنی بر شبکه عصبی به نام خودرمزنگار وجود دارد. برای جزئیات بیشتر در مورد نحوه اعمال کاهش ابعاد در داده های زیست پژوهی، خواننده را به یک بررسی اخیر ارجاع می دهیم.^{۱۵}

نمونه هایی از کاربردهای یادگیری ماشین بدون ناظارت خوشه بنده بطور گسترده در تجزیه و تحلیل داده های با ابعاد بالا، مانند آزمایش های رونویس، متابولومیک و پروتئومیک، مورد استفاده اتفاق رفته است. معمولاً از خوشه بنده مراتب سلسه مراتب برای شناسایی عوامل مؤثر بر خوشناسی ها و همچنین برای شناسایی مازول هایی با درجه بالایی از تنظیم همسو استفاده می شود. در توالی یا بین تک سلولی، از خوشه بنده غیرسلسله ای برای درک انواع سلول های موجود در نمونه استفاده می شود. خوشه بنده همچنین برای شناسایی بیماری های بیماران، بافت ها، بیماری های یا حتی علائم اساس بیان ژن، حساسیت و خواص پروتئین هدف دسته بنده شوند.^{۱۶} با هدف هدایت کشف دارو.

کاهش ابعاد به طور معمول در آزمایش های ترانسکریپتومیک و سایر آزمایش های omics، معمولاً برای شناسایی داده های پرت و اثرات دسته ای بالقوه، استفاده می شود. در توالی یا بین تک سلولی، تقریب منیفولد بکنوخت و تصویرسازی یا جاسازی همسایه تصادفی توزیع شده هم برای تجسم داده ها و هم برای خوشه بنده بعدی استفاده می شوند.^{۱۷} کاهش ابعاد همیشه بزرگترین هدف دسته بنده شیمیایی با ابعاد بالا استفاده می شود.^{۱۸} یا به عنوان یک مرحله پیش پردازش برای بهبود عملکرد یک مدل یادگیری ماشین.^{۱۹}

- غذاهای اصلی خوشه بنده می تواند برای درک ساختار داده ها با گروه بنده مشاهدات مشابه با هم مورد استفاده قرار گیرد.
- ک خوشه بنده به معنای ابزاری ساده اما قدرتمند است، با این حال، تعداد خوشه ها باید از قبل مشخص شود.
- روش های مبتنی بر چگالی به تعداد از پیش تعیین شده ای از خوشه ها نیاز ندارند و امکان شناسایی الگوهای پیچیده در داده ها را فراهم می کنند.
- خوشه بنده سلسه مراتب، یک نمای کلی از رابطه در سطوح مختلف ارایه می دهد.
- کاهش ابعاد نه تنها برای تجسم داده ها، بلکه برای حذف ویژگی های غیرمفید نیز استفاده می شود.

یادگیری تحت ناظارت در یک مسئله یادگیری ناظارت شده، داده های آموزشی به همراه مشاهدات و مقادیر خروجی شناخته شده ای متناظر به کامپیوترا داده می شود. هدف، یادگیری قوانین کلی (که اغلب «مدل» نیز نامیده می شود) است که ورودی ها را به خروجی هانگاشت می کنند، به طوری که پیش بینی ... امکان پذیر باشد.



شکل ۳ نمایش مسئله‌ی کم برازش/بیش برازش در یک مورد رگرسیون ساده. نقاط داده با نقاط آبی و برازش مدل با خطوط قرمز نشان داده شده‌اند. کم برازش با یک مدل خطی (پانل سمت چپ)، برازش خوب با یک چندجمله‌ای درجه ۴ (پانل مرکزی) و بیش برازش با چندجمله‌ای درجه ۲ (پانل سمت راست) رخ می‌دهد. جذر میانگین مربعات خطابه عنوان تابع هدف برای ارزیابی خطای آموزش و خطای تعیین انتخاب شده است که با استفاده از اعتبارسنجی متقابل ۱-fold ارزیابی می‌شود.

میانگین مربعات خطای تابع هدف لجستیک یا آنترپی متقاطع، برای یافتن پارامترهای بهینه یا ارزیابی برازش مدل استفاده می‌شوند. در عمل، محاسبه تحلیلی حداقل درستنمایی یا حداقل زیان ممکن است امکان پذیر نباشد و اغلب لازم است از یک الگوریتم بهینه سازی عددی برای حل مسئله و یافتن بهترین مقادیر پارامتر استفاده شود. گرایان نزولی چنین الگوریتمی است که در آن ابتدا یک تابع هدف تعريف من کنیم که من خواهیم آن را به حداقل برسانیم و سپس به طور تکراری مقادیر پارامترها را در جهتی که شدیدترین کاهش (مشتق مرتبه اول) تابع هدف رخ می‌دهد، به روزرسانی کنید تا زمانی که همگرایی به حداقل فاصله حاصل شود. در سناریوی تابع هدف غیرمحدب، موقوفیت یافتن یک حداقل سراسری، برخلاف رسیدن به برخی حداقل‌های محلی، به انتخاب مجموعه اولیه مقادیر پارامتر، رخ یادگیری (یعنی اندازه گام هر تکرار) و معیار همگرایی بستگی دارد. خواننده می‌تواند به مرجع ... مراجعه کند.^۵ برای جزئیات بیشتر در مورد فرآیندهای بهینه سازی محدب و غیرمحدب. نزول گرایان تصادفی یک ترفند اضافی است که من تواند با نمونه برداری تصادفی از یک مجموعه داده آموزشی و جمع کردن فواصل در این زیرمجموعه از نقاط داده آموزشی برای تقریب تابع هدف، بهینه سازی را سرعت بیشتری بخشد.

اصول کلی انتخاب و ارزیابی مدل. مشکل بیش برازش نشان می‌دهد که عملکرد مدل روی مجموعه داده آموزشی، ساختار خوبی برای عملکرد آن روی مجموعه داده جدید نیست. در ادامه اصول ارزیابی عملکرد مدل در یک محیط یادگیری نظارت شده را شرح خواهیم داد.

اصل کلی انتخاب مدل به شرح زیر است: وقتی داده‌های کافی وجود داشته باشد، آنها را به سه زیرمجموعه تقسیم می‌کیم - مجموعه های آموزشی، اعتبارسنجی و آزمون. مجموعه آموزشی برای ساخت مدل‌های مختلف استفاده می‌شود، در حالی که مجموعه اعتبارسنجی متعاقباً برای انتخاب الگوریتم و در صورت نیاز، انتخاب اپریامترها استفاده می‌شود. سپس، مدلی که بهترین عملکرد را در مجموعه اعتبارسنجی دارد انتخاب می‌شود. در نهایت، مجموعه آزمون امكان ارزیابی خطای تعیین را فراهم می‌کند که به آن خطای تعیین نیز گفته می‌شود. خطای آزمون که خطای پیش‌بینی روی یک مجموعه داده آزمایشی است

در حالت رگرسیون، شکل ۳ مسئله‌ی کم برازش و بیش برازش را در زمینه‌ی رگرسیون نشان می‌دهد. کم برازش می‌تواند زمانی رخ دهد که مدل خیلی ساده باشد و یزگی‌های استخراج شده از داده‌ها به اندازه‌ی کافی آموزنده نباشند (شکل ۳، پنل سمت چپ). بیش برازش اغلب زمانی رخ می‌دهد که مدل بیش از حد پیچیده باشد یا یزگی‌های زیادی در یک مجموعه کوچک از مثال‌های آموزشی وجود داشته باشد (شکل ۳، پنل سمت راست).

این مشکل کم برازش/بیش برازش اغلب به عنوان بده بستان بایاس/واریانس نیز شناخته می‌شود، که از بیان خطای پیش‌بین مورد انتظار، شامل هر دو عبارت بایاس و واریانس، ناشی می‌شود. بایاس نشانه‌ای از میانگین خطای مدل برای مجموعه‌های آموزشی مختلف است: این اختلاف بین میانگین مقادیر پیش‌بین شده و میانگین واقعی است که ماسعی در پیش‌بین آن داریم. واریانس نشان دهنده حساسیت مدل به مجموعه‌آموزشی است: برای یک نقطه معین، با پراکندگی مقادیر پیش‌بین شده در اطراف میانگین آنها مطابقت دارد.

برای به حداقل رساندن خطای پیش‌بین شده، بین به حداقل رساندن بایاس و واریانس، بده بستان و وجود دارد: افزایش پیچیدگی مدل، بایاس را کاهش می‌دهد اما واریانس را افزایش می‌دهد. برای ساخت مدل های ساده‌تر، تکنیک‌های مختلف وجود دارد که تحت عنوان منظم سازی خلاصه شده‌اند. اصل این روش شامل اصلاح تابع هدف با اضافه کردن عبارات جرمیه‌ای است که بر تخمین پارامتر تأثیر می‌گذارند. منظم سازی L1 و L2 رایج ترین آنها هستند (ESL، بخش ۹.۳.۴.۲).

دسته‌بندی‌های مختلف توابع زیان. هدف متفاوت توابعی را می‌توان برای اندازه گیری فاصله بین داده‌های مشاهده شده و مقادیر پیش‌بین شده توسط مدل انتخاب کرد. برخی از معیارهای فاصله‌ای که در عمل استفاده می‌شوند را می‌توان به ... مرتبط کرد.

احتمال درستنمایی نشان می‌دهد که مشاهده داده‌های ما طبق مدل انتخاب شده چقدر محتمل است. رایج‌ترین کاربرد درستنمایی، یافتن پارامترهایی است که مدل را به طور بهینه با داده‌ها برازش می‌دهند (یعنی تخمین های پارامتر درستنمایی حداکثری). معمولاً، لگاریتم منفی درستنمایی به حداقل می‌رسد و به عنوان تابع هدف در نظر گرفته می‌شود زیرا خواص عددی مطلوبی دارد. به طور مشابه، در معیارهای یادگیری ماشین، مانند

در مقابل، معیار اطلاعات بیزی:
 آی سی=In (ن-م-۲ لیتر).

(3) تعداد نقاط داده را در نظر می‌گیرد.
 این رویکردهای انتخاب مدل به ندرت در یادگیری ماشینی استفاده می‌شوند، که بخشی از آن به دلیل پیچیدگی مجموعه داده‌ها و نقص فرضیات توزیعی مرتبط است. در عوض، رویکردهای مانند اعتبارسنجی متقابل (خوش بندی) بیشتر مورد استفاده قرار می‌گیرند.

معیارهای عملکرد برای ارزیابی مدل برای رگرسیون در مدل‌ها، ما معمولاً از میانگین مرباعات خطایا انواع دیگر توابع هدف میانگین برای مقایسه عملکرد مدل در مجموعه آموزش و آزمون استفاده می‌کنیم. برای مسائل طبقه بندی دو کلاسه، معیارهای عملکرد رایج اغلب از «ماتریس سردگم» نشان داده شده در شکل ۵ و به طور خلاصه در زیر توضیح داده شده است.

- دقت، مربوط به نسبت مقادیر مثبت درست پیش‌بینی شده به تعداد کل مقادیر مثبت پیش‌بینی شده.
- یادآوری، که نرخ مثبت واقعی (TPR) نیز نامیده می‌شود و مربوط به نسبت مقادیر مثبت پیش‌بینی شده‌ی صحیح به تعداد کل مقادیر مثبت در مجموعه داده‌ها است.
- نرخ مثبت کاذب (FPR)، مربوط به نسبت مقادیر منفی پیش‌بینی شده‌نادرست است.
- دقت، مربوط به تعداد مقادیر درست پیش‌بینی شده تقسیم بر تعداد کل مقادیر پیش‌بینی شده.
- مساحت زیر منحنی ROC: منحنی‌های مشخصه عملیاتی گیرنده (ROC) وابستگی TPR (فرآخوان) و FPR را نشان می‌دهند. چگالی در طبقه بندی دودویی، هر نقطه روی منحنی ROC با انتخاب آستانه‌های مختلف برای طبقه بندی ... مکان یابی می‌شود. یعنی در کلاس مثبت یا منفی، گوشه بالا سمت چپ منحنی ROC با تعداد پارامترها و حداقل احتمال.

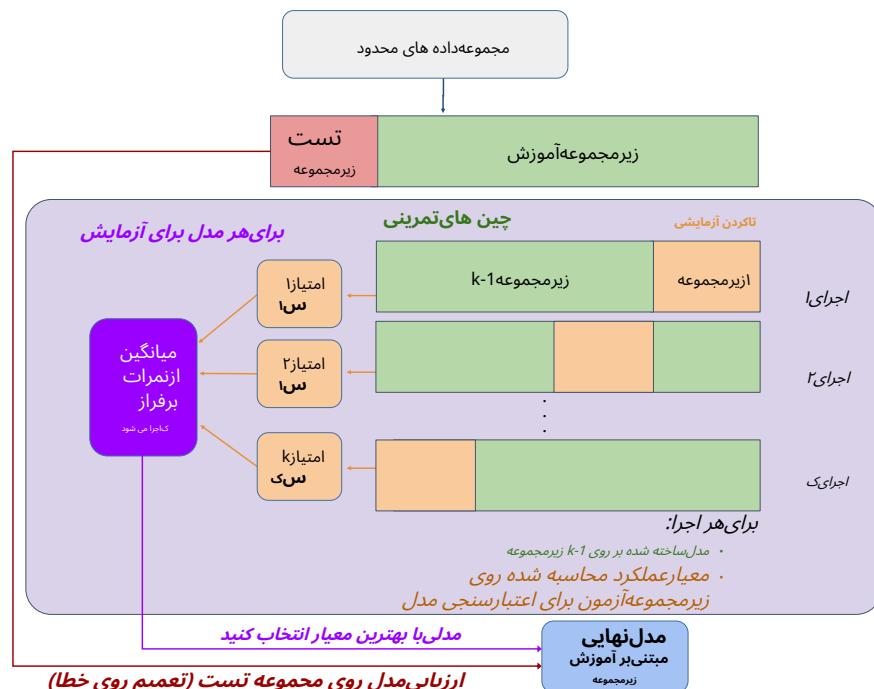
که در طول آموزش استفاده نشده است. لازم به ذکر است که وقتی مجموعه داده‌های اصلی دارای سوگیری باشند، خطای تعیین من تواند بیشتر از حد انتظار باشد (به بخش «داده‌ها و ویژگی‌ها» مراجعه کنید). اعتبارسنجی مدل در برابر یک مجموعه داده آزمایش کاملاً مستقل، روش استاندارد طلایی برای ارزیابی تعیین پذیری مدل است.

وقتی مجموعه داده‌ها برای استخراج یک مجموعه اعتبارسنجی مناسب بسیار کوچک است، به عنوان مثال، می‌توان از تکنیک‌های اعتبارسنجی مقابل برای انتخاب ابیریارامترهای مدل استفاده کرد. پس از کنار گذاشتن زیرمجموعه‌ای از داده‌های هابرای زیرمجموعه‌ها، ک-ازیرمجموعه‌هایی که برای آموزش استفاده می‌شوند است. ک-ازیرمجموعه‌ای که برای ارزیابی عملکرد استفاده می‌شود. این فرآیند تکرار می‌شود که هر کدام ک-ازیرمجموعه‌هایی برای هر مجموعه از ابیریارامترها برای آزمایش، میانگین گیری می‌شوند. ک-روش اعتبارسنجی متقابل برابر در خلاصه شده است شکل ۴ برای انتخاب بین الگوریتم‌های یادگیری مختلف^۳ می‌توان از اعتبارسنجی متقابل تو در تو استفاده کرد.

شاخص‌های پیچیدگی مدل در مقابل خوبی برازش در در فارماکومتریک، انتخاب مدل معمولاً بر اساس معیارهای کمی است که خلاصه می‌کنند مدل چقدر خوب با داده‌ها برازش دارد، که اغلب با جرمیه‌هایی برای بیش برازش همراه است. رایج‌ترین آنها معیار اطلاعات آکائیک و معیار اطلاعات بیزی هستند. آنها تعداد پارامترهای مدل را جرمیه می‌کنند و به خوبی برازش، که از طریق درستنمایاندازه گیری می‌شود، پاداش می‌دهند. معیار اطلاعات آکائیک به صورت زیر فرموله می‌شود:

(2) آی سی=2-م-۲ لیتر.

با تعداد پارامترها و حداقل احتمال.



شکل ۴ آزمایش اصول کل یادگیری نظارت شده در مورد یک مجموعه داده محدود. برای ارزیابی توانایی تعیین یک الگوریتم یادگیری نظارت شده، داده‌ها به یک زیرمجموعه آموزش که برای ساخت مدل استفاده می‌شود و یک زیرمجموعه آزمایش که برای ارزیابی خطای تعیین استفاده می‌شود، تفکیک می‌شوند.

		برجسب های پیش بین شده	
		0	1
TPR = پادآوری (نرخ مثبت واقعی) $\frac{TP}{TP+FN}$	منفی کاذب (FN)	موقعیت واقعی (TP)	1
	منفی واقعی (TN)	موقعیت کاذب (FP)	0
دقت $\frac{TP+TN}{TP+TN+FN+FP}$	نرخ منفی کاذب $\frac{FN}{TP+TN+FN+FP}$	دقت $\frac{TP}{TP+FN}$	

برجسب های واقعی (مشاهدات)

شکل ۵ ماتریس درهم ریختگی برای مسائل دو کلاسه. ماتریس درهم ریختگی نشان می دهد که الگوریتم در پیش بینی برجسب ها در یک مسئله طبقه بندی دودویی که برجسب های مقادیر ۰ (به نام «منفی») یا ۱ (به نام «مثبت») را می گیرند، با ارزیابی برجسب های واقعی، چقدر موفق بوده است. هر نقطه داده در مجموعه آزمون متعلق به یکی از چهار دسته است و می توان معیارهای مختلفی را از این اعداد استخراج کرد.

یک روش طبقه بندی بسیار مؤثر در عمل، این روش در آموزش (یعنی ذخیره داده هادر پایگاه داده) و پیاده سازی های کارآمد برای محاسبه ... بسیار کارآمد است. ک شبکه های عصبی (NN) وجود دارند. خوب، چالش های این رویکرد چیست؟ واضح ترین چالش این است که چون هیچ «مرحله یادگیری» وجود ندارد، ک رویکرد شبکه های عصبی، ویژگی های را که واقعاً برای پیش بینی کلاس یک مورد جدید مرتبط هستند، شناسایی نمی کند. بنابراین، حتی اگر در یک فضای ویژگی ۲۰ بعدی، که در آن فقط ۲ مورد ممکن است واقعاً برای طبقه بندی مرتبط باشد، فاصله ای در نظر گرفتن هر ۲۰ بعد محاسبه خواهد شد. بنابراین، ک نزدیکترین نقاط داده ای که توسط پرس و جو برگردانده می شوند، به شدت تحت تأثیر ویژگی های نامریوط یا نویز قرار خواهد گرفت (همچنین به «کاهش ابعاد» در مورد نحوه حذف برخی از این ویژگی ها مراجعه کنید). در نتیجه، طبقه بندی حاصل به جای الگوی واقعی زیرینای در داده ها، توسط نویز هدایت می شود. از این نظر، این رویکرد از همان چالش رنج می برد که رویکردهای خوش بندی (به بخش «خوش بندی» مراجعه کنید) با آن مواجه هستند، که اغلب به عنوان «نفرین ابعاد» خلاصه می شوند.^{۲۱}

بیزساده دومین رویکرد یادگیری بسیار شهودی که می خواهیم معرفی کنیم، بیزساده است. این رویکرد مبتنی بر محاسبه آمار ساده از یک مجموعه داده آموزشی معین به عنوان مرحله یادگیری است که پس از یک کاربرد ساده (اما ساده) از فرمول بیزی برای احتمال شرطی به منظور دستیابی به یک طبقه بندی انجام می شود. به دلیل سادگی آن، اغلب برای دستیابی به یک عملکرد طبقه بندی پایه نیز استفاده می شود که سایر روش های پیچیده تر باید آن را بهبود بخشد. این رویکردا من توان با یک مثال ساده به بهترین شکل توضیح داد. فرض کنید مجموعه داده های آموزش شامل بیمارانی داریم که از سرماخوردگی بی ضرر یا عفونت آنفولانزا رنج می برند. ما برای هر بیمار دو ویژگی، یعنی تب (بالا، پایین یا بدون تب) و درد (قوی، پایین یا بدون تب) را اندازه گیری کرده ایم. برای هر بیمار، از طریق آزمایش آزمایشگاهی می دانیم که آیا بیمار به عفونت آنفولانزا مبتلا بوده است یا خیر. اکنون می خواهیم از این داده ها یاد بگیریم و آن را برای تشخیص یک بیمار جدید (در جایی که هیچ آزمایشگاهی در دسترس نداریم) با استفاده از رویکرد بیز ساده به کار ببریم. به عنوان یک مرحله یادگیری، برای هر مقدار ویژگی، تعداد دفعات وقوع آن را در گروه بیماران مبتلا به آنفولانزا و سرماخوردگی محاسبه می کنیم (متلاً برای به دست آوردن احتمال تب بالا در شرایط ابتلای بیمار به آنفولانزا و غیره) نتیجه این مرحله یادگیری را می توان در ... مشاهده کرد. **جدول ۱**.

حالات ایده آل این است که ۱۰۰٪ مقادیر مثبت به درستی طبقه بندی شوند (TPR = ۱) و ۰٪ مقادیر مثبت به اشتباه در ... پیش بینی شوند (FPR = ۰). از آنجایی که ایده آل این است که TPR را به حداقل FPR را به حداقل برسانیم، مساحت زیر منحنی ROC بزرگتر است.

برخی از این معیارها را می توان برای مسائل چندکلاسه، که در آن هاییش از دو برجسب مختلف در مجموعه داده ها وجود دارد، تعیین مداد. با این حال، معیارهای ذکر شده در بالا نسبت به پارامترهای مدل غیربررسی شده هستند، از این رو، بهینه سازی پارامتر ممکن است هنگام استفاده از آن ها به عنوان تابع هدف چالش برانگیز باشد. یک معیار جایگزین پیوسته و پرکاربرد که قبلاً در بخش «برآراش مدل» ذکر شد، آنتروپی متقاطع است (ESL، فصل ۹)، که نه تنها محتمل ترین پیش بینی، بلکه امتیاز پیش بینی (اعتماد به پیش بینی) را نیز در نظر می گیرد.

ک-نزدیکترین همسایه ها

مابرسی اجمالی خود را بر روی روش های یادگیری موجود با روش آغاز می کنیم که مرحله یادگیری را به طور کامل حذف می کند و بنابراین، منجر به یک مدل صریح که از داده های آموزشی آموخته می شود، نمی شود. همانطور که بعداً بحث خواهیم کرد، این نیز یکی از بزرگترین کاستی های آن است. این نوع یادگیری اغلب به عنوان "یادگیری مبتنی بر نمونه" نیز شناخته می شود و در مثال خاص ما، "ک-یادگیری تزدیکترین همسایه" (kNN) در این رویکردها، یادگیری صرفاً شامل ذخیره تمام نقاط داده و برجسب گذاری شده (یعنی داده های آموزش) در یک پایگاه داده است. هنگامی که یک مثال جدید، اما طبقه بندی نشده، مشاهده می شود، گوییم آن را در ... قرار می دهد. فضای ویژگی چندبعدی بر اساس مقادیر ویژگی آن. برای هر نقطه داده در پایگاه داده، اکنون فاصله (مثلثه اقلیدسی) فاصله های پیچیده تر دیگر را تا این نقطه داده جدید محاسبه می کنیم تا آن را شناسایی کنیم. ک-نزدیکترین همسایگان. در مرحله دوم، برجسب های شناخته شده این موارد را بررسی می کنیم که شبکه های عصبی در پایگاه داده ما، فرض کنید ممکن است که این فاصله اقلیدسی که هفت نااز نزدیکترین همسایه ها به عنوان کلاس X برجسب گذاری شده اند در حال که دو تا از آنها به عنوان کلاس Y برجسب گذاری شده اند. در این حالت، نقطه داده جدید خود را به کلاس X اختصاص می دهیم زیرا اکثر همسایه های آن از این کلاس هستند. بسط این رویکرد ساده، وزن دهن به اهمیت همسایه ها در طبقه بندی بر اساس فاصله آنها تا نقطه داده جدید است. با وجود اینکه بسیار سرراست و ساده است، اما ثابت می شود که ...

جدول ۱ تصویرسازی بیز ساده: نمونه ای از نتایج مرحله یادگیری روی مجموعه داده آنفولانزا، که احتمال مقادیر ویژگی ها را با توجه به دسته بیمار نشان می دهد.

درد	تب	ویژگی ها
خیر	کم	کلاس ها
پ(درد = بیرون آنفولانزا) = .۰۵	پ(درد = شدید آنفولانزا) = .۲۰	پ(تب = بیرون آنفولانزا) = .۹۵
پ(درد = کم آنفولانزا) = .۷۵	پ(درد = خیر آنفولانزا) = ۰	پ(تب = بیرون آنفولانزا) = .۰۵
پ(تب = بالا آنفولانزا) = .۰۱	پ(تب = بالا آنفولانزا) = .۹۹	پ(سرد) = .۹
پ(تب = سرد) = .۱	پ(تب = سرما) = .۴	پ(تب = بالا سرما) = .۱

مقادیر در صورت رگرسیون. در روزهای اولیه یادگیری ماشین، از درخت های تصمیم برای حل مسائل دارویی مانند دوزبندی، سم شناسی و تشخیص استفاده شده است.^{۱۳-۲۲} اگرچه استفاده از درخت های تصمیم گیری شهودی است، اما سوال این است که چگونه من می توان چنین درخت هایی را از داده های موجود ساخت. چند رویکرد معروف که ارزش ذکر کردن دارند عبارتند از: CART^{۲۳} و ID3^{۲۴}.

در حال حاضر، درخت های تصمیم تقریباً هرگز در یادگیری ماشین به شکل اصلی خود استفاده نمی شوند. یکی از دلایل این امر این است که درخت های تصمیم مستعد بیش برازش هستند. با این وجود، درخت های تصمیم به سنگ بنای دو رویکرد پرکاربرد تبدیل شده اند: جنگل های تصمیم تصادفی و چارچوب های تقویت گردایان.

هم جنگل های تصمیم گیری تصادفی و هم تقویت گردایان مبتنی بر درخت از مجموعه ای (گروهی) از درخت های تصمیم گیری آموزش دیده برای پیش بینی متغیر نتیجه استفاده می کنند. تقاضوت اساسی بین تقویت گردایان مبتنی بر درخت و جنگل های تصادفی، الگوریتم صدها یا هزاران درخت در مرور جنگل های تصادفی، الگوریتم صدها یا هزاران درخت تصمیم گیری عمیق ("پیش بینی کننده های قوی") من سازد. هر یک از این درخت ها احتمالاً بیش برازش شده اند، با این حال، با ترکیب خروجی های چندین درخت می توانیم مشکل آموزش بیش از حد را حل کنیم. بر عکس، در یک الگوریتم افزایش گردایان، مانند CatBoost^{۲۵} یا XGBoost^{۲۶}، هر یک از درخت هایی که درخت تصمیم گیری کم عمق ("پیش بینی کننده ضعیف") هستند الگوریتم به طور تکراری با اضافه کردن درختان بیشتر و بیشتر، خطای طبقه بندی را در طول زمان کاهش می دهد.

امروزه، روش های تقویت گردایان، عملکرد بسیار خوبی را هم در نشریات و هم در مسابقات یادگیری ماشین نشان می دهند. حتی بدون تنظیم های پیرامتر، آنها معمولاً عملکرد عالی را با هزینه محاسباتی نسبتاً کم ارائه می دهند.^{۱۱} از طرف دیگر، جنگل های تصادفی معمولاً کمتر مستعد بیش برازش هستند.^{۲۷} و نیاز به تنظیم پارامترهای کمتری دارند.^{۱۶} این امر، جنگل های تصمیم گیری تصادفی را برای مجموعه داده های کوچک تریا به عنوان یک روش پایه برای الگوبرداری جذاب می کند.

روش های گروه درختی می توانند برای وظایف طبقه بندی و همچنین برای رگرسیون استفاده شوند. در هر دو مورد، خروجی های درخت میانگین گیری می شوند که من تواند یک روش پایه برای الگوبرداری جذاب من کند.

روش های هسته: ماشین های بردار پشتیبان و رگرسیون روش های کرنل و به طور خاص تر، ماشین بردار پشتیبان (SVM) برای طبقه بندی و رگرسیون بردار پشتیبان (SVR) برای خروجی پیوسته، به دلیل توانایی شان در مقاوم بودن در برابر نویز و کار با مجموعه داده های با عبعاد بالا که در ژنتیک، ترانسکریپتومیکس و پروتئومیکس یافت می شوند، کاربردهایی در زیست شناسی محاسباتی پیدا کرده اند.^{۲۸-۳۷} به طور مخصوص در یک مثال جدیدتر، از SVR برای مشخص کردن ترکیبات سلولی از داده های حجمی رونویسی استفاده شد.^{۳۸}

جدول ۱ احتمال هر ویژگی را با توجه به دسته بیمار خلاصه می کند و نشان می دهد که در کل جمعیت بیمار، احتمال ابتلای یک بیمار به عفونت آنفولانزا ۱۰٪ است، در حالی که احتمال ابتلای به سرماخوردگی معمولی ۹٪ است.

وقتی این مقادیر را تولید کردیم و بنابراین «مرحله یادگیری» را با تجزیه و تحلیل مجموعه داده های خود تکمیل کردیم، بیز ساده لوحانه یک فرض ساده لوحانه مطرح می کند، و آن این است که همه این ویژگی ها از نظر شرطی مستقل از یکدیگر هستند. در واقعیت، این به ندرت صادق است و روش های یادگیری بیزی پیشرفت تری وجود دارند که این فرض را در نظر ننمی گیرند. با این حال، این فرض امکان کاربرد ساده ای از قضیه بیزی را فراهم می کند. برای جزئیات (یعنی فرمول ها) در مورد نحوه استخراج این طبقه بندی کننده، خواننده را به مطالب بیشتر برای مطالعه ESL^{۳۹}، فصل ۶ ارجاع می دهیم. به طور خلاصه، احتمال یک برعسب خاص (آنفولانزا یا سرماخوردگی) برای یک آیتم آزمایش جدید را من توان به صورت حاصلضرب احتمالات ویژگی شرطی واحد (تب و درد) که برای نقطه داده مشاهده می شوند، در احتمال کلاس (آنفولانزا یا سرماخوردگی) محاسبه کرد. کلاسی که بیشترین احتمال پسین را دارد، به عنوان کلاس پیش بینی شده برای آیتم آزمایش انتخاب می شود. با فرض اینکه یک فرد آزمایشی با تشخیص ناشناخته آنفولانزا یا سرماخوردگی داریم و من دانیم که این فرد با تب بالا و تب بالا مراجعه می کند.

اگر سطح درد بالا باشد، احتمال ابتلای آنفولانزا را به صورت زیر محاسبه می کنیم:

$$P(\text{تب} = \text{بالا} | \text{آنفولانزا}) \cdot P(\text{درد} = \text{شدید} | \text{آنفولانزا})$$

$$P(\text{آنفولانزا}) = 0.95 = 0.75 \cdot 0.95 = 0.7125$$

به همین ترتیب، احتمال سرماخوردگی را به صورت زیر محاسبه می کنیم:

$$P(\text{تب} = \text{بالا} | \text{سرماخوردگی}) \cdot P(\text{درد} = \text{شدید} | \text{سرد})$$

$$P(\text{سرد}) = 0.1 = 0.3 \cdot 0.1 = 0.03$$

برای بیماری که با تب بالا و درد عضلانی یا سردد شدید به پزشک مراجعه می کند، این امر منجر به احتمال خلفی (غیر نرمال) برای عفونت آنفولانزا ۷.۱۲۵٪ و احتمال ۲.۷٪ برای سرماخوردگی معمولی می شود. بنابراین، بیمار بیشتر از سرماخوردگی از آنفولانزا رنج می برد.

بنابراین، بیز ساده لوحانه، از بسیاری جهات، چگونگی یادگیری انسان ها از تجربه را فرموله می کند.

درخت های تصمیم، جنگل های تصادفی و تقویت گردایان درخت های تصمیم، بلوک های سازنده ی ضروری برای بسیاری از الگوریتم های یادگیری ماشین هستند و حداقل ۵ سال است که مورد استفاده داده های ۱۳٪^{۳۹} ایده پشت درخت های تصمیم گیری بسیار شهودی است و بهترین شکل به صورت تصری نمایش داده می شود (مثلاً **شکل ۱**). این ابسته به مسئله، گره های برگ درخت تصمیم دارای کلاس، احتمال یا پیوسته هستند.

فضای ویژگی. یک تابع هسته که در فضای ورودی اعمال می شود، معادل یک ضرب نقطه ای در فضای ویژگی است که در آن معیارهای شباهت محاسبه می شوند. این امر بدون نیاز به نگاشت صريح داده های ورودی از فضای ورودی به یک فضای ویژگی توسعه یک تابع نگاشت، محقق می شود.

بادر دست داشتن تمام این مفاهیم، اکنون می توانیم مدلی با ضخامت مشخص، که به عنوان لوله ای که توسط تابع زبان *-insensitive SVM* معرفی می شود، برازش دهیم، در حالی که عبارت منظم سازی، مسطح بودن این ابرصفحه را در فضای ویژگی تعریف شده توسعه تابع هسته کنترل می کند. **شکل ۶** این مفاهیم اساسی SVM را نشان می دهد.

ترفندو انتخاب هسته: می تواند توابع هدف غیرخطی را ثبت کند که ورودی های چند متغیره را به خروجی نگاشت می کند. به طور دقیق تر، ترفندهسته به این معنی است که یک هسته SVR

$$(6) \quad \text{ک}(\text{ایکس}_i, \text{ایکس}_j) = \phi(\text{ایکس}_i) \cdot \phi(\text{ایکس}_j)$$

اعمال شده بر مجموعه ای از ورودی ها در فضای ورودی معادل محاسبه ضرب نقطه ای به عنوان معیار شباهت در برخی از فضای ویژگی هاست. این امر بدون نیاز به انجام صریح پیش نگاشت ورودی ها حاصل می شود. **ایکس** من، با یک تابع نگاشت. یک تابع هسته محاسبه شده در فضای ورودی، اگر و تنها اگر یک تابع متقابل مثبت معین باشد، معادل یک ضرب نقطه ای در یک فضای ویژگی است. ۵۱.۵۲. انتخاب هسته تابع پایه ساعی،

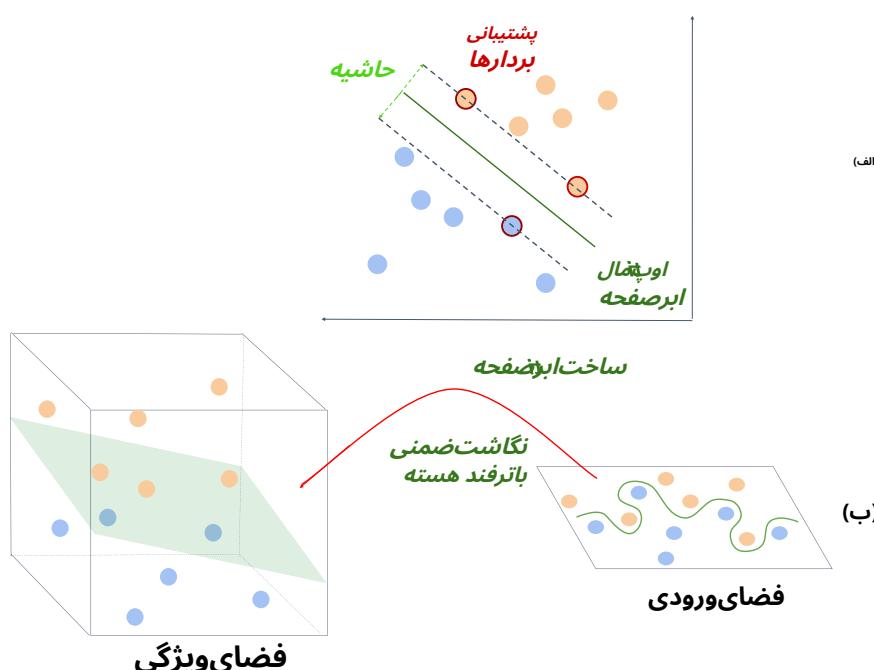
$$(7) \quad \text{ک}(\text{ایکس}_i, \text{ایکس}_j) = \exp(-\| \text{ایکس}_i - \text{ایکس}_j \|_2^2)$$

اغلب به این دلیل ساخته می شود که می توان آن را به یک فضای ویژگی با ابعاد نامتناهی گسترش داد. اگرچه تابع پایه ساعی طیف وسیعی را پوشش می دهد

این بخش ابتدا مروری مختصر بر مفاهیم کلیدی ارائه می دهد که مفاهیم تبدیلات هسته، یک تابع هدف با ناحیه بدون اتفاق و یک عبارت منظم سازی را بر جسته می کند. ۴۹.۵. تأکید بر ارایه استدلال پشت این موضوع خواهد بود که چرا این روش در برخورد با ورودی های چندگانه که اثرات آنها بر خروجی ناشناخته است و می توان فرض کرد که به توابع غیرخطی تبدیل می شوند، روشی تطبیق پذیرتر است.

پیشیه: مشابه تمام روش های رگرسیون، هدف *SVR* فرض تابعی روی ورودی(ها) است که می تواند به تخمین خروجی مشاهده شده کمک کند. به همین ترتیب، برای SVM، هدف یافتن مرز تصمیم گیری بهینه است که کلاس ها را از هم جدا می کند. همانطور که از نامش پیداست، مفهوم اصلی پشت SVM/Rگرسیون، توانایی انتخاب عینی زیرمجموعه ای از داده های آموزش به نام ... است. برداهای پشتیبانی این بردارهای پشتیبان، مدل را تعریف می کنند که معمولاً یک ابرصفحه در فضای ویژگی است. برای دستیابی به این هدف، باید چندین مفهوم معرفی شوند.

- یک از دست دارن غیرحساس تابع اجازه می دهد تا باقیمانده های کمتر از بدون اتفاق در نظر گرفته شوند و بنابراین، بخشی از بردارهای پشتیبان در نظر گرفته شده برای تخمین تابع خروجی-ورودی نباشند.
- **الف:** اصطلاح منظم سازی با هدف جستجوی مدل برای توصیف رابطه بین متغیرهای ورودی و خروجی به تابع هدف اضافه می شود به طوری که ابرصفحه تا حد امکان مسطح نگه داشته شود.
- متغیرهای اسلک می توان برای در نظر گرفتن خطاهای آموزش، که حاشیه نرم نامیده می شود، زمانی که خروجی خارج از ناحیه غیرحساس θ یافت می شود، معرفی کرد. با معرفی متغیرهای slack، تحمل برای عبارت باقیمانده که بزرگتر از θ باشد، ایجاد می شود.
- **الف:** تابع هسته به ما اجازه می دهد در فضای با ابعاد بالاتر کار کیم،



شکل ۶: تصویرسازی اصول ماشین بندار پشتیبان (SVM). (الف) تصویرسازی از یک حالت ساده که در آن یک ابرصفحه، دو گروه را مستقیماً در فضای ورودی ها از هم جدا می کند. (ب) نمایش انجام طبقه بندی غیرخطی با نگاشت ضمنی ورودی ها به فضاهای ویژگی با ابعاد بالا که در آن نقاط داده می توانند توسعه یک ابرصفحه از هم جدا شوند.

شبکه‌های عصبی بازگشتنی، شبکه‌های عصبی بازگشتنی، دسته‌ای از شبکه‌های عصبی هستند که به مجموعه داده‌های سری زمانی اختصاص دارند، زیرا رابطه ترتیبی ذاتی مشاهده شده در داده‌های یک نقطه زمانی با نقطه زمانی دیگر را در نظر می‌گیرند. این شبکه‌ها در چیزی که در این زمینه به عنوان ... شناخته می‌شود، موفقیت کسب کرده‌اند. داده‌های ترتیبی، جایی که ترتیب یا توالی زمانی سیگنال نقشی ایفا می‌کند، یعنی در پردازش زبان طبیعی و پیش‌بینی سری‌های زمانی. این روش که ارتباط نزدیکی با حوزه تحقیقاتی ما دارد، در پیش‌بینی نتایج حاصل از پروندهای الکترونیکی سلامت کاربرد پیدا کرده است، جایی که غنای آن ذاتاً از ساختار همبستگی توالی داده‌ها ناشی می‌شود تا اقدامات سریع و حتی پیش‌بینی شده‌ای را که باید توسط کادر پزشکی انجام شود، توصیه کند.^{۵۷} طرح مجدد سوال برای حل یک معما مدل سازی در حالت نگارش فارماکومتری، تنها زمانی شروع به ظهور کرد که این مقاله در حال نگارش بود. تانگو همکاران یکی از تلاش‌های نادر در مورد نحوه استفاده از ML (RNN‌ها) برای توصیف PK ریمتانیل را ارائه داده و نتایج را با روش استاندارد طلایی فارماکومتریک NONMEM مقایسه کرده‌اند.^{۵۸}

اگرچه از مدل‌های غیراستاندارد PK برای مقایسه استفاده شد و تعمیم پذیری نتایج من تواند مورد مورد چالش قرار گیرد، تانگو همکاران... سهم ارزشمندی در نشان دادن کاربردهای RNN‌ها در فارماکومتری داشته باشد.

شکل پایه یک RNN در شکل نشان داده شده است. **شکل ۷ ب** که در آن هر حالت فعلی (در زمان آنی) با ترکیبی از حالت قبلی سیستم و ورودی فعلی تعریف می‌شود، که مشابه مفهوم سیستم‌های دینامیک‌کلاسیک است. وزن‌های هر لبه را می‌توان تعیین کرد که چقدر باید به عقب نگاه کرد، مشابه یک ثابت زمانی. برخلاف شبکه عصبی پیش‌خور، یک وزن یکسان در بلوک واحد نورونی منفرد در تمام مراحل زمانی گسترش قابلی به اشتراک گذاشته می‌شود.

در هسته RNN، از یک توالی ورودی تشکیل شده است که توسط ... تعریف می‌شود. ایکس(t)، یک دنباله خروجی مطابق تعریف زیرات)، یک توالی حالت پنهان یا سیستم که به صورت زیر تعریف می‌شود(t) و همچنین زیرمدول‌های زنجیری از واحدهای تکراری.

مراحل مورد نیاز برای آموزش یک مدل RNN به شرح زیر است:

۱. معماری شبکه را تعریف کنید و مدل را با وزن‌ها و بایاس‌های تصادفی مقداردهی اولیه کنید.
۲. برای محاسبه خروجی تخمینی، یک انتشار را به جلو انجام دهید.
۳. خطای را در لایه خروجی محاسبه کنید.

از اثرات احتمالی، منجر به تفسیر دشوارتر مدل نهایی می‌شود. در عمل، انتخاب تابع هسته بر اساس کارایی محاسباتی است. سایر هسته‌های محبوب شامل هسته‌های خطی و چندجمله‌ای هستند.^{۵۹}

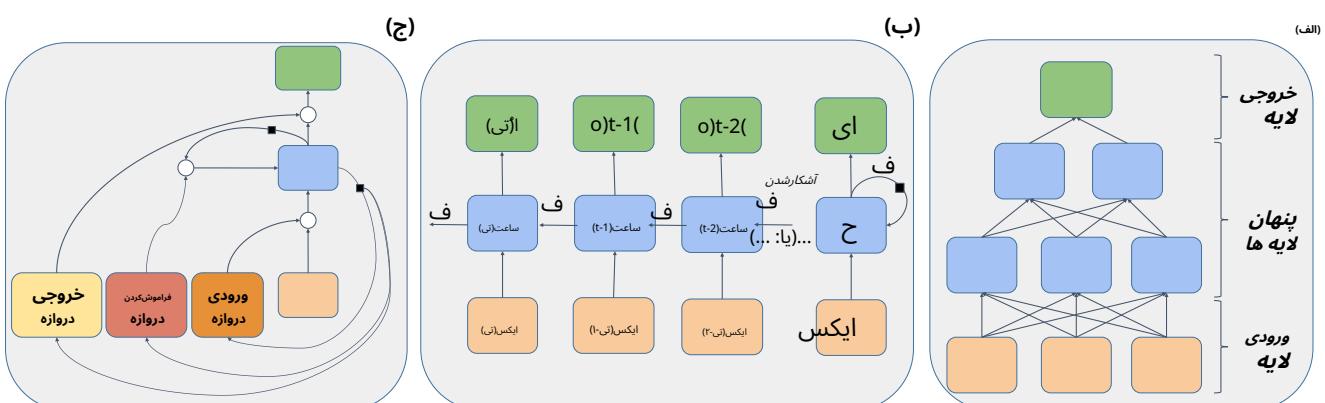
شبکه‌های عصبی

پیشینه. شبکه‌های عصبی مجموعه‌ای از نورون‌ها و لبه‌ها را تشکیل می‌دهند که منشأ آنها از تحلیل مدار گرفته شده است. می‌توان وزن‌های مختلف را به هر لبه متصل کننده نورون‌ها اعمال کرد. در هر نورون، یک تابع فعال سازی به یک سیگنال خروجی تولید شود. اغلب از یک تابع سیگموئیدی استفاده می‌شود که شامل یک فیلتر پایین گذر مرتبه اول از یک تابع پله واحد است. چنین تابع سیگموئیدی مزایای خروجی کران دار و مشتق پذیری پیوسته را دارد که در مرحله انتشار رو به عقب برای تنظیم وزن‌ها (پارامترهای مدل) مورد نیاز است، به مراحل تعریف شده در بخش «شبکه‌های عصبی بازگشتنی» مراجعه کنید.^{۶۰}

نورون‌ها همانطور که در شکل نشان داده شده است، به لایه ورودی، لایه‌های پنهان و لایه خروجی تقسیم می‌شوند. **شکل ۷ الف** لایه‌های پنهان، لایه انتزاع مورد نیاز برای رفتار از لایه ورودی به لایه خروجی را انجام می‌دهند. تعداد لایه‌های پنهان مشخص می‌کند که آیا سیستم یک سیستم یادگیری سطحی (با یک یا چند لایه پنهان) یا یادگیری عمیق (با لایه‌های پنهان زیاد) است. بین تعداد لایه‌های پنهان و زمان نیاز برای آموزش مدل، یک بده بستان ذاتی وجود دارد. به همین دلیل، اگرچه مفهوم اصلی تعییه شده در شبکه عصبی، مفهوم جدیدی نیست، اما به دلیل پیشرفت‌های اخیر در قدرت محاسباتی، کاربردهای جدیدی پیدا کرده است.

اساسی ترین نوع آن به عنوان شناخته می‌شود پیشخور شبکه عصبی، زیرا اطلاعات فقط از لایه ورودی به لایه‌های پنهان و در نهایت به لایه خروجی منتشر می‌شود. وضعیت فعلی سیستم توسط هیچ وضعیت گذشته‌ای تعریف نمی‌شود؛ از این‌رو، یک سیستم بدون حافظه را نشان می‌دهد.

در ادامه، نمونه‌هایی از شبکه‌های عصبی شرح داده شده است: شبکه‌های عصبی بازگشتنی، شبکه‌های حافظه کوتاه مدت بلندمدت و شبکه‌های بازگشتنی دروازه دار، شبکه‌های عصبی قابل توجه دیگری که خارج از محدوده این مقاله هستند اما مطالعه بیشتر در مورد آنها را توصیه می‌کنیم، عبارتند از شبکه‌های عصبی کانولوشنی،^{۶۱} شبکه‌های رمزگذار-رمزگشایی،^{۶۲} و مدل‌های تولیدی.^{۶۳}



شکل ۷: شبکه‌های عصبی (الف) مبانی شبکه‌های عصبی بازگشتنی. (ب) آشکار شدن شبکه‌های عصبی پیش‌خور. (ج) آشکار شدن شبکه‌های عصبی بازگشتنی. مریع سیاه نشان دهنده تأخیر یک گام زمانی گسترش است.

نمونه هایی از کاربردهای یادگیری ماشینی تحت نظرارت در داروشناسی بالینی

مدل های موجود در فارماکولوژی بالینی معمولاً با ترجمه اصول فیزیولوژیک و دارویی به سیستم های معادلات دیفرانسیل و استفاده از الگوریتم های حداکثرسازی انتظار برای تخمین پارامترهای مدل ایجاد شده اند. این رویکرد با انگیزه مکانیکی در بسیاری از کاربردها مفید بوده و یک جزء ثابت شده از برنامه های توسعه دارو است. به طور بالقوه به دلیل موقیت این رویکردهای ثابت شده، تاکنون تنها چند نمونه از اعمال روش های یادگیری ماشین در مسائل فارماکولوژی بالینی وجود دارد. ریوو همکاران یک شبکه عصبی عمیق رابر روی یک پایگاه داده بزرگ و منظم که شامل ۱۹۲۲۸۴ تداخل دارو با دارو بود، آموزش داد تا تداخلات دارو با دارو و دارو و غذا را برای نسخه ها، توصیه های غذایی و مولکول های جدید پیش بینی کند.^{۶۰} ترکیب مجموعه داده های حاصل از مطالعات متعدد برای ایجاد پایگاه های داده بزرگ، پتانسیل استفاده از یادگیری ماشین را برای پرداختن به سوالات گسترده داروشناسی بالینی افزایش من دهد.

همچنین از یادگیری ماشین برای ایجاد پل بین کشف دارو و توسعه بالینی استفاده شده است. به عنوان مثال، هامان و همکاران تواستند با استفاده از روش درخت تصمیم گیری، میزان بروز عوارض جانبی را از ساختار شیمیابی یک مولکول پیش بین کنند.^{۶۱} به طور مشابه، لنکستر و سوبن SVM ها را برای پیش بینی خطر de Pointes Torsades از ... پیاده سازی کردند. در شرایط آزمایشگاهی (*in vitro*) داده ها^{۶۲}

در حوزه اینمنی شخصی سازی شده، یادگیری ماشین توسط دانه اواره مورد استفاده قرار گرفته است. و همکاران شخصی سازی اینمنی در زمینه هیپریلیروبینمی در نوزادان^{۶۳}، نویسندها از لاسو و جنگل های تصادفی برای پیش بینی از مجموعه داده های بالینی استفاده کردند. علاوه بر این، یادگیری تقویتی توسط گاودا مورد استفاده قرار گرفت. و همکاران برای شخصی سازی مدیریت دارویی کم خونی^{۶۴}، از رویکرد مشابهی برای توسعه یک سیستم «حلقه بسته» برای کنترل گلوکز با ترکیب یک مدل ریاضی، یک حسگر گلوکز و یک مدل یادگیری تقویتی استفاده شد.^{۶۵} چاواد و همکاران و هنینگو همکاران امکان سنجی بازخورد بیزی برای تنظیم دوز آتنی بیوتیک هارا بررسی کردند.^{۶۶} حوزه مراقبت های بهداشتی شخصی سازی شده می تواند از استفاده از مدل های یادگیری ماشین که تنظیمات دوز را در زمان واقعی توصیه می کنند، بسیار بهره مند شود. در یک مطالعه اخیر، یک الگوریتم کنترل از نوع یادگیری ماشین با مدل های ساختاری موجود PK/PD که برای متخصصان داروشناسی آشنا هستند، ادغام شد و مشخص شد که سیستم کنترل حلقة بسته حاصل، عملکرد بهتری نسبت به پمپ با کمک حسگر دارد.^{۶۷}

غذاهای اصلی

- روش های یادگیری نظارت شده، مدل ها را بر اساس جفت های خروجی-ورودی برچسب گذاری شده ای مجموعه داده های آموزش استنتاج می کنند.
- معیارهای عملکرد برای ارزیابی مدل های طبقه بنده و رگرسیون استفاده می شوندتا از بیش برآش مجموعه داده های آموزش جلوگیری شود.
- روش های یادگیری نظارت شده ی زیادی با بدنه بستان های مختلف بین تفسیرپذیری و عملکرد وجود دارند.
- شکل خاصی از شبکه عصبی است که یک سیستم پویا را در زمان گسترش نمایش می دهد RNN
- نمونه هایی از کاربردهای این روش های یادگیری تحت نظرارت در زیست شناسی محاسباتی و به ویژه داروشناسی بالینی در حال پیدا شدن هستند.

بحث

در این آموزش، ما برخی از روش های اساسی یادگیری ماشین را معرفی کرده ایم که احتمالاً برای فارماکولوژی بالینی جالب خواهد بود.

۴. با استفاده از یک رویکرد بهینه سازی، یک الگوریتم انتشار معکوس برای به روزرسانی وزن ها انجام دهد.

۵. مراحل ۲ تا ۴ را برای تعداد دوره ها (یا تکرارها) تکرار کنید تا مقدار تابع زیان به حداقل برسد.

افزونه های این و اینل شبکه های عصبی بازگشته (RNN) برای رسیدگی به مشکلات مربوط به گرادیان ناپایدار (مثلاً مشکل گرادیان ناپدیدشونده و معادل جدی تر آن، ناپایداری ناشی از گرادیان انفحاری) توسعه داده شدند. این مشکلات در اصل به دلیل ضرب هایی (تحت تأثیر خطاهای عددی) هستند که در انتشار معکوس در رابطه با تخمین خطای نسبت به پارامترها در امتداد هر لایه از شبکه عصبی ایجاد می شوند. به عبارت دیگر، گرادیان ناپدید شونده باعث من شود اطلاعاتی که باید از یک نقطه زمانی دورتر از زمان فعلی ثبت شوند، ضعیف شوند و بنابراین، مدل را برای ثبت حافظه ذخیره شده ارزشمند با تأخیر زمانی طولانی تر، ضعیف می کنند. در یک رویداد کمتر رایج که حداقل یک مشتق جزئی الزام پایداری را نقض کند، و به همان ترتیب حالت داشتن حداقل یک مقدار ویژه < 1 تبدیل شود، این امر منجر به یک مشکل گرادیان انفحاری می شود، یک مشکل شناخته شده در سیستم پویای سنتی برای زمان گستته. وظیفه موردا استفاده برای رسیدگی به این مشکل اساسی، در دو افزونه شناخته شده RNN (حافظه کوتاه مدت طولانی (LSTM) و شبکه بازگشته در روازه دار (GRU)) بیشتر توضیح داده خواهد شد.

انواع و توسعه های مختلفی در تحقیقات RNN وجود داشته است، هر روش جدید برای پرداختن به یک مسئله متفاوت به کار من روکده در نهایت منجر به توسعه مدل های قوی تر می شود. به عنوان مثال، برای دور زدن مشکل گرادیان ناپایدار، برش گرادیان با مجبور کردن گرادیان به یک آستانه در مرجع پیشنهاد شده است.^{۵۹،۶۰} اما تاکنون پذیرفته شده ترین روش، گنجاندن واحدهای در روازه ای.

حافظه کوتاه مدت بلند و شبکه بازگشته در روازه دار LSTM بخشی از خانواده بزرگتری از RNN های در روازه دار است که با معرفی واحدهای در روازه ای، اطلاعات را حفظ و فراموش می کنند. به طور خاص تر، همانطور که در نشان داده شده است، می توان سه واحد در روازه ای را در سیستم گنجاند. **شکل ۷** اول، کپی کردن یا پاک کردن مستقیم کل حالت می تواند توسط گیت فراموش کنترل شود. رویکرد مشابهی نیز توسط گیت و رویدی برای تصمیم گیری در مورد اینکه آیا سیگنال ورودی فعلی را به عنوان بخشی از به روزرسانی حالت در نظر بگیرد یا خیر، انجام می شود. مقدار اطلاعاتی که باید از سیگنال حالت قبلی و از سیگنال ورودی اختلال حفظ شود، در هر گام زمانی آموخته می شود. اسیستم باید با حفظ اطلاعات، وابستگی های زمانی بلند مدت را باید بگیرد، اما باید گاهی اوقات نیز یادگیرید که اطلاعات را از وضعیت فعلی خود پاک کند.^{۶۱} درنتیجه، حل مسائل گرادیان ناپدید شونده و انفحاری در نهایت، می توان یک گیت خروجی، هرچند کمتر رایج، را به عنوان یک مکانیسم گیتینگ برای تصمیم گیری در مورد اینکه کدام سیگنال خروجی به سیستم بازگردانده شود، معرفی کرد.

یک تفسیر ساده تر و در نتیجه، پیاده سازی سریع تر آموزش را می توان در GRU یافت. GRU ها همان مشکل گرادیان های ناپایدار را برطرف می کنند و یک افزونه جدید به این خانواده از افزونه های RNN هستند. تفاوت اصلی بین LSTM و GRU این است که دومی گیت خروجی را حذف کرده و از گیت های ریست و به روزرسانی ساده تری استفاده می کند.^{۶۲} اما این حال، در تئوری، LSTM باید عملکرد بهتری داشته باشد زیرا می تواند اطلاعات را از فاصله زمانی/تاخیر طولانی تر، وزن دهنی یا وزن دهنی کند.

توسعه. به دلیل این موقوفیت، علیرغم ورود یادگیری ماشینی، انتظار نمی‌رود که اهمیت و فعالیت رویکردهای کلاسیک فارماکومتری کاهش یابد. در مقابل، می‌توان آنها را با دانش و بینشی که توسط روش‌های مدل‌های یادگیری ماشینی استخراج شده است، تقویت و بهبودبخشید.

یک‌چالش مداوم برای اعضای جامعه داروشناسی بالینی که مایل به استفاده از روش‌های یادگیری ماشین هستند، شیوع ذاتی داده‌های طولی است. تاکنون، روش‌های یادگیری ماشین زیادی وجود دارند که برای پیش‌بینی به ویژگی‌های پایه متکی هستند، اما نمونه‌های نسبتاً کم وجود دارد که در آن‌ها از داده‌های طولی استفاده شده باشد. در مجموع، ما انتظار داریم که هرگز یک رویکرد جهانی و یکسان برای همه وجود نداشته باشد که مدل سازان از حوزه‌های مختلف به آن روی آورند. ما خاطرنشانان کنیم که حوزه‌های زیادی از هم افزایی بالقوه وجود دارد که در آن حاوزه‌های مدل سازی در حوزه توسعه دارو با هم همپوشانی دارند. جامعه داروسازی بالینی به پایه گذاری تحلیل‌های خود بر اساس اصول دارویی ادامه خواهد داد و به تدریج عناصر جدید یادگیری ماشین را به گردش کارخود اضافه خواهد کرد و مدل‌های خود را بیشتر تقویت خواهد کرد. علاوه بر این، جامعه داروسازی بالینی قادر خواهد بود طیف وسیعی از سوالاتی را که می‌تواند با استفاده از رویکردهای یادگیری ماشین به آن‌ها پاسخ دهد، افزایش دهد.

تأمین‌مالی
تأمین‌مالی شده است F. Hoffmann-La Roche Ltd. این مطالعه توسط Roche دریافت کننده بورسیه پسادکتری IID

تضاد منافع
نه نویسنده‌گان هیچ‌گونه تضاد منافعی برای این اثر اعلام نکردند.

© 2020 نویسنده‌گان فارماکولوژی بالینی و درمان شناسی منتشر شده توسعه انتشارات‌وابیلی، به نماینده از انجمن آمریکایی فارماکولوژی و درمان شناسی بالینی.

-NonCommercial-NoDerivs Creative Commons Attribution است که استفاده و توزیع در هر رسانه ای را مجاز می‌داند، مشروط بر اینکه به اثر اصلی به دست اینجا به اثر اصلی به دست اینجا به اینجا تغییر یا اقتباس انجام نشود.

۱. کاماقو، دی، ام، کالینز، کی، ام، پاورز، آر کی، کاستلو، جی سی و کالینز، جی جی. یادگیری ماشینی نسل بعدی برای شبکه‌های بیولوژیک. سالول ۱۷۳-۱۵۹۲، ۱۵۸۱-۱۵۹۲.
۲. شن، دی. وو، جی. و سوک، اچ-آی. یادگیری عمیق در تحلیل تصاویر پیشکش. سال. کشیش، زیست پژوهشی. مهندسی. ۲۰۱۷ (۲۴۸-۲۲۱).
۳. راجکومار، آ، دین، جی. و کوهان، آی. یادگیری ماشین در پیشکش. مجله پیشکش انگلستان (J. Engl. J. Med.) ۱۹۸۰-۱۹۷۸، ۳۱۸-۳۱۷.
۴. کلاین، اس. س. نمایش رویدادها در شبکه‌های عصبی و اتوماتای متناهی (ADA596138) / نیروی هوایی پروژه زند، سانتا مونیکا، کالیفرنیا، (۱۹۵۱) <https://apps.dtic.mil/docs/citations/>.
۵. بیرمن، ل. مدل سازی آماری: دو فرهنگ (همراه با توضیحات و پاسخ نویسنده). آمار علم، ۱۶، ۲۳۱-۱۹۹.
۶. ریبری، ام، تی، سینگ، اس. و گستربن، سی. «چرا باید به شما اعتماد کنم؟»: توضیح پیش‌بینی‌های هر طبقه‌بندی کننده‌گان مجموعه مقایلات پیست و دومین کنفرانس بین‌المللی ACM SIGKDD در زمینه کشف داشش و داده کاوی، سانفرانسیسکو، کالیفرنیا ۱۷ آگوست ۲۰۱۶.
۷. استدولم، ای. و کونوتو، آی. توضیح مدل‌های پیش‌بینی و پیش‌بینی‌های منفردیا مشارکت ویژگی‌های داشش. سیستم اطلاعاتی، ۱۴، ۶۴۷-۶۴۷.
۸. ایپتون، زد. سی. افسانه تفسیری‌ذیری مدل‌صف ACM ۱۶، ۳۱-۵۷.
۹. هاستنی، ت.، تیپشیرانی، ر. و فریدمن، ج. عناصر یادگیری آماری: داده کاوی، استنتاج و پیش‌بینی (انتشارات اسپریتگر نیوبیورک، نیوبیورک، نیوبیورک، ۲۰۰۸).
۱۰. جز، جی. امو همکاران جایگذاری داده‌های گمشده با استفاده از روش‌های آماری و یادگیری ماشین در یک مسئله واقعی سرطان سینه. مصنوع. هوشمند. پژوهش.

وجامعه فارماکومتری. مقدمه مختصر ما با طیف وسیعی از منابع مرتبط تکمیل شده است. ما با ذکر مثال‌های مرتبط با توسعه دارو، زمینه را فراهم کرده ایم. در پایان، خلاصه‌ای از وضعیت فعلی حوزه‌های یادگیری ماشینی و فارماکولوژی بالینی و همچنین چشم اندازی از چگونگی ادغام بیشتر این حوزه‌ها در آینده ارائه می‌دهیم. روش‌های آماری پیشرفته برای فارماکومتری دانان جدید نیستند؛ بر واقع، چنین روش‌هایی مدتی است که برای توصیف پدیده‌های PK و PD استفاده می‌شوند. به عنوان مثال، روش‌های پیزیکی یک جزء جافتاده از رویکردهای فارماکومتری هستند.^{۷-۲۷}

بنابراین، به نظر من رسید که با ثبت و برجسته تر شدن رویکردهای آماری و یادگیری ماشینی در صنعت داروسازی، متخصصان فارماکومتری از حمله کسانی خواهند بود که از این روش‌ها بهره من برند. علاوه بر این، فرصت‌های جدیدی برای بررسی سایر سوالات بالینی، مانند طبقه‌بندی بیمار بر اساس ویژگی‌های پایه با ابعاد بالا، ممکن است در فارماکولوژی بالینی با استفاده از رویکردهای یادگیری ماشینی امکان پذیر شود.

چندین نمونه از رویکردهای یادگیری ماشینی که در سوالات فارماکولوژی بالینی به کار گرفته شده اند، شامل ادغام تکنیک‌های مدل سازی «کلاسیک»، مانند تعیین یک مدل ساختاری مبتنی بر درک‌مکانیسمی، و رویکردهای یادگیری ماشینی است.^{۷-۶۹} رویکردهای فارماکومتری کلاسیک مبتنی بر اصول فارماکولوژیکی هستند که فرضیه‌های حاصل از درک فیزیولوژی و خواص دارو را معنکس می‌کنند. بعید است که این مدل‌ها در آینده نزدیک به طور کامل با رویکردهای یادگیری ماشینی جایگزین شوند. با این حال، هنگامی که مجموعه داده‌ها و مسائل پیچیده تر هستند، تأثیرات و روابط ناشناخته زیادی وجود دارد و تمرکز بر درون پایی و ارزیابی سریع است.

فارماکومتری ممکن است از به کار گیری روش‌هایی از نوع یادگیری ماشینی بهره مند شود. در ادامه، انتظار داریم که تلفیق این درک با مدل‌های یادگیری ماشینی تواند به مدل‌های بسیار مؤثری در آینده منجر شود. یک مقاله اخیر با دیدگاهی جدید، جزئیات بیشتری در مورد کاربردهای یادگیری ماشینی در فارماکولوژی بالینی ارائه می‌دهد.^{۷۴} در عصر کلان داده، فرصت‌های جدید زیادی برای یادگیری ماشینی در داروشناسی بالینی وجود دارد. به عنوان مثال، داده‌های تولید شده از دستگاه‌های پوشیدن، چالش‌های جدیدی را در مورد چگونگی پیوند آنها با داده‌های PK در آینده ایجاد می‌کنند. علاوه بر این، دسترسی به داده‌های دنیای واقعی می‌تواند شواهد مکمل برای متغیرهای کمک، مجموعه داده‌های کنترل مکمل و مدل‌های تقویت کننده ای که روی مجموعه داده‌های کوچک آموزش دیده اند، فراهم کند.

در رویکردهای فارماکومتری، یک مدل پیش‌بینی کننده معمولاً با ادغام یک مدل ساختاری و داده‌های مرتبط ایجاد می‌شود. مدل ساختاری به طور قابل توجهی فضای راه حل را محدود می‌کند و بنابراین، داده‌های نسبتاً کمی برای برآوردن مدل مورد نیاز است. بر عکس، در شبکه‌های عصبی، ساختار مدل از پیش مشخص نشده است و بنابراین، داده‌های نسبتاً بیشتری برای ساخت یک مدل پیش‌بینی کننده مورد نیاز است. همچنین لازم به ذکر است که ما هنوز در مرحله ابتدایی درک هستیم که در آن نقطه ادغام داده‌های بزرگتریا این روش‌های سنتی تر مفید باشد. چالش زیره ۷ پیش‌بینی در مقایسه با روش‌هایی سنتی تر می‌باشد. سری های زمانی نشان می‌دهد که ترکیب روش‌های آماری کلاسیک و یادگیری ماشینی دقیق ترین پیش‌بینی را ایجاد می‌کند و بنابراین، آن را به عنوان راهی برای پیشنهاد می‌دهد. یک از محرك‌های اصلی موقوفیت رویکردهای فارماکومتری این است که مدل‌های شامل درک کاملی از فرآیندهای جذب، توزیع، متabolیسم و حذف دارو هستند. مدل‌های ایجاد شده بسیار پیش‌بینی کننده هستند و بنابراین، کاربرد گسترده‌ای در پشتیبانی از دارو پیدا می‌کنند.

۱۱. دورگوش، ای وی، ارشوف، وی، و گولین، ای. کت بوسن: تقویت گرادیان پشتیبانی از ویژگی های دسته بندی شده. *arXiv arXiv:1810.11363* (۲۰۱۸).
۱۲. نظریه تصحیح سوگیری انتخاب نمونه. در (eds). *Zeugmann, T.*, Mohri, M., Riley, M., Rostamizadeh, A., Freund, Y., Györfi, L., Turán, G. & Aظریه یادگیری الگوریتمی. ۳۸-۵۳ (اشپرینگر، ۲۰۰۸).
۱۳. ای، بن. کی، لسلر، جی. و استوارت، ای. ای. بهبود وزن دهن امتیاز گرایش با استفاده از یادگیری ماشین آمار، پژوهشکی، ۲۹-۳۴۶، ۳۴۷، ۲۹ (۲۰۱۰).
۱۴. بیوبی، دی. فریتابس، ای. ای. و غفوریان، تن. مقابله با مجموعه داده های کلاس نامتعادل در مدل های جذب خوارکی. *مجله شیمی. مدل اطلاعات*, ۵۱، ۴۶-۴۷ (۲۰۱۳).
۱۵. هو، ای. اچ، هوانگ، ام-دبیلو، کی، اس-دبیلو، و نسای، سی-اف. تأثیر تابع فاصله بر طبقه بندی k-نزدیک ترین همسایه برای مجموعه داده های پژوهشکی. *اسپرینگر پلیسنس*, ۵-۱۳ (۲۰۱۶).
۱۶. بروزان، ای. وات، اس. و فرنی، وی. ادغام معیارهای شباهت توالی مبتنی بر هم ترازوی بدون هم ترازوی برای طبقه بندی توالی های زیست بیو انفورماتیک (۲۰۱۵-۱۴۴-۱۳۹۶)، ۳۱.
۱۷. کولیسون، ای. ای. بیلی، بی. چانگ، دی. کی. و بیانکین، ای. وی. زیرگرهای مولکولی سرطان پانکراس. *Rev. Gastroenterol.* ۱۶-۲۲-۲۷ (۲۰۱۹).
۱۸. لوبید، اس. انتزیراسون کمترین مریعات در PCM. *نظریه انتقال اطلاعات IEEE*, ۱۳۷-۱۳۹۲، ۲۸ (۱۹۸۲).
۱۹. خوشبندی مبتنی بر چگالی. *Kriegel, H.-P., Kröger, P., Sander, J., Zimek, A.* حداقل دانش داده های بازیابی شده. *دیسکاوی*, ۱-۲۳۰ (۲۰۱۱).
۲۰. استر، م. کریگل، اچ-بی. ساندر، جی. و شو، XA. الگوریتم مبتنی بر چگالی برای کشف خوشه ها، یک الگوریتم مبتنی بر چگالی برای کشف خوشه ها در پایگاه های داده مکانی بزرگ با نویز. *مجموعه مقاالت دومین کنفرانس بین المللی کشف دانش و داده کاوی*. *AAAI Press, Portland, OR, 1996*, 226-231.
۲۱. زیمک، آ.، شوربرت، ای. و کریگل، اچ-بی. بررسی تشخیص داده های پرت بدون نظارت در داده های عددی با ابعاد بالا. *داده های آماری. تحلیلی. حداقل*, ۵-۳۶۳ (۲۰۱۲).
۲۲. پیرسون، ک. درباره خطوط و صفحات که بیشترین برازش را به سیستم های نقطادر فضای دارند. *مجله فلسفی و مجله علمی لندن، ادینبورگ و دوبلین*, ۲-۵۵۹ (۱۹۱۹).
۲۳. van der Maaten, L. & Hinton, G. t-SNE. *جی. ماخ پژوهش های یادگیری*, ۹-۵۷۹ (۲۰۰۸).
۲۴. بخت، ای. و همکاران کاهش ابعاد برای متصورسازی داده های تک سلولی با استفاده از UMAP. *نات، بیوتکنولوژی*, ۳۷-۳۸۰ (۲۰۱۹).
۲۵. نگوین، ال اچ و هولمز، اس. ده نکته سریع برای کاهش ابعاد مؤثر. *e1006907 (۲۰۱۹)*.
۲۶. وانگ، سی.، ماجیراچو، آر. و هوانگ، کن. طبقه بندی بیماران سرطان سینه با استفاده از روش خوشه بندی اجتماعی منظم مولکولی. *روش ۳۱۳-۳۴۶-۷۵۷* (۲۰۱۴).
۲۷. کوپر، جی. اس.، باینوم، ام. ال و سامرز، ای. سی. بینش های اخیر در ایدمیوژی بیماری های خودایمنی: بهبود تخمین شیوع و درک خوشه بندی بیماری ها جی. خودایمنی, ۳-۱۹۷، ۳۰۷ (۲۰۰۹).
۲۸. والش، دی. و ریبیکی، ال. خوشه بندی علائم در سرطان پیشرفته، پشتیبانی. *مراقبت سرطان*, ۱۴-۸۳۶ (۲۰۰۶).
۲۹. کسرسیروم ژوتیپ-بیان بافت (GTEX) و همکاران آنالیز آزمایش ژوتیپ-بیان بافت (GTEX): تنظیم ژن چند بافتی در انسان. *علم ۶۴۸-۶۴۸*, ۳۴۸ (۲۰۱۵).
۳۰. زانگ، جی. دی. برنتیس، ان. راث، ای. و ابلینگ، ام. داده کاوی شبکه ای از ژن های باسخ اولیه را به عنوان امراض اجتماعی سمیت ناشی از دارو در شرایط آزمایشگاهی (*in vitro*) و بدون بدن (*in vivo*) آشکار می کند.
۳۱. فارماکوتوموگیک جی. ۱۴-۲۰۸، ۲۰۶ (۲۰۱۴).
۳۲. جما، آو. همکاران خوشه بندی داروهای ضد سرطان در سرطان ریه بر اساس پروفایل های بیان ژن و پایگاه داده حساسیت سرطان. *BMC ۱۷۴-۱۷۴*.
۳۳. کخ، ام. و والدم، اج. خوشه بندی شباهت ساختار پروتئین و ساختار محصول طبیعی به عنوان اصول راهنمای در کشف دارو کشف مواد مخدوش. *امروز ۴۷۱-۴۷۱*, ۱-۴۸۳ (۲۰۰۵).
۳۴. روتلینگر، م. و اشتایدر، گ. کاهش ابعاد غیرخطی و نگاشت کتابخانه های ترکیبات برای کشف دارو نمودار. *مدل. مجله مول*, ۱۱۷-۱۱۷ (۲۰۱۱).
۳۵. عزت، آ.، وو، م.، لی، ایکس-آل. و کو، سی-کی. بیش بینی برهمکنش دارو-هدف بالاستفاده از یادگیری جمعی و کاهش ابعاد. *روش ۱۲۹-۱۲۸*, ۸۸-۸۸ (۲۰۱۷).
۳۶. نستروف، ی. سخنرانی های در مورد بهینه سازی محدب. *جلد ۱۳۷* (اشپرینگر، ۲۰۱۸).
۳۷. کاولی، جی. سی و تالبوت، ان. ال. سی. درباره بیش برازش در انتخاب مدل و سوگیری انتخاب بعدی در ارزیابی عملکرد جی. *ماخ یادگیری. پژوهش*, ۱۱-۲۰۷، ۲۰۷-۲۰۱ (۲۰۱۰).
۳۸. میچل، تی. امیادگیری ماشین ((شرکت مک گرا-هیل، نیویورک, ۱۹۹۷).
۳۹. بیلسون، دبیلو، ای. تطبیق و بیش بینی بر اساس اصل طبقه بندی بیولوژیکی آمار R/ جامعه آماری. گروه C. آمار کاربردی. ۸۷-۶۵-۸۷ (۱۹۵۹).
۴۰. کریشر، جی. پی. کتابشناسی مشروط از کاربردهای تحلیل تصمیم گیری در مراقبت های هدایتشن اعلیات. *۹۷-۹۸*, ۹۷-۹۸ (۱۹۸۰).
۴۱. شورتیف، ای. اچ، بوكانان، بی. جی و فیگباوم، ای. ای. مهندسی دانش برای کامپیوت. *مجموعه مقاالت IEEE ۱۲۲۴-۱۲۲۵*, ۷-۸ (۱۹۷۹).
۴۲. باخ، بی. اچ و برجز، جی. دبیلو، رویکرد درخت تصمیم گیری بالینی مبتنی بر متابولیسم سینتیک دارو در آزمایش های سم شناسی و داروشناسی درون تن و برون تن قوس. *توکسیکول. مکمل*, ۸-۱۷۳، ۱۸۸ (۱۹۸۵).
۴۳. جردن، تی. جی و رایشمن، ال. بی. دوزاژ یک بار در روز در مقابل دوز دو بار در روز تیوفیلین: یوکردی برای تحلیل تصمیم گیری جهت ارزیابی سطح خونی تیوفیلین و میزان بذریش. *جانب کشیش، تنفس*. دیس (۱۹۸۹).
۴۴. بربین، ل. فریدمن، ج. اولشن، ر. و استون، س. درخت های طبقه بندی و رگرسیون گروه بین المللی واردورت ۳۷-۳۷ (۱۹۸۴).
۴۵. کوبلان، جی. آی. القای درخت های تصمیم گیری. *ماخ یادگیری. ماخ ۱۰-۸۱*, ۱-۱۶ (۱۹۸۶).
۴۶. بربین، ل. جنگل های تصادفی. *ماخ یادگیری. ماخ ۴-۴۵*, ۳-۳۲-۵ (۲۰۰۱).
۴۷. Ben-Hur, A., Ong, CS, Sonnenburg, S., Schölkopf, B. & Rätsch, Z. ماشین های بردار پشتیبان و هسته ها برای زیست شناسی محاسباتی. *PLOS Comput. Biol.*, e1000173 (۲۰۰۸).
۴۸. نیومن، آو. همکاران شمارش دقیق زیرمجموعه های سلولی از پروفایل های بیان بافت. *روش های طبیعی*, ۴۵۷-۴۵۳ (۲۰۱۰).
۴۹. کنترل اتوماتیک. *رم. ۲۲-۷۷۴*, ۷۸-۷۸ (۱۹۶۳).
۵۰. اسموسلا، ای. و لزن، ای. تشخیص الگو با استفاده از روش پرتره تعییم یافته. *پشتیبان آمار، محاسبات*, ۱۹۹-۲۲۲ (۲۰۰۴).
۵۱. مرسی، جی. توابع از نوع متبت و منفی و ارتباط آنها با نظریه معادلات انتگرال. *فلسفه ترجمه. آر. جامعه شناسی، لندن*. بی. زیست. علمی, ۴۴۶-۴۱۵ (۱۹۹-۱۹۹).
۵۲. Schölkopf, B. & Smola, AJ. یادگیری با هسته ها: ماشین های بردار پشتیبان، منظم سازی، بهینه سازی و فراتر از آن (انتشارات MIT، کمبریج، ماساچوست، ۲۰۰۲).
۵۳. کریفسکی، آی. ساتسکور، آی. و هیتنون، جی. ای. طبقه بندی ایدمیج نت با شبکه های عصبی کانولوشن عمیق. *پیشرفت ها در سیستم های پردازش اطلاعات عصبی*, ۱۱-۱۰۷، ۲۵ (۲۰۱۱).
۵۴. چو، ک. و همکاران یادگیری نمایش عبارات با استفاده از رمگذار-رمگذار RNN برای ترجمه ماشینی آماری. *پیش چاپ ۱۰۷۸ (۱۴۰۶)* (arXiv arXiv:1406.1078).
۵۵. چو، ک. ون مریبوئر، ب. بادهاناو، د. و بجیو، ی. یادگیری ویژگی های ترجمه یادگیری بصیرتی: یوکردهای رمگذار-رمگذار ۱۲۵۹. *arXiv preprint* (۲۰۱۴).
۵۶. کینگما، دی. بی. محمد، اس. رزنه، دی. جی و ولینگ، ام. یادگیری نیمه نظراتی با مدل های مولد عیقیز. *NIPS'14: مجموعه مقاالت پیشت و هفتین کنفرانس بین المللی سیستم های پردازش اطلاعات عصبی*, ۳۵۸۱-۳۵۸۳ (۲۰۱۴).
۵۷. چو، ای. و همکاران شروع نارساین قلبی. *Dashgakhi*, arXiv:24/2/361/26314999 (OUP) (۲۰۱۶).
۵۸. تانگ، جی-تن، کائو، واي، شیایو، جی-واي، و گوئو، کيو-ال. پیش بینی غلط پلاسماین رمیفنتایل بر اساس شبکه عصبی المن. دانشگاه جن، سنت جنوی، ۲۰۱۸-۳۱۸۷ (۲۰۱۳).
۵۹. پاسکانو، ر. میکولوف، ت. و بجیو، ی. در مورد دشواری آموزش شبکه های عصبی بازگشتی. *کنفرانس بین المللی یادگیری ماشین، اینیورگ*, ۲۶-۲۰-۱ (۲۰۱۳).
۶۰. ژوئیه ۱-۱۳۱۰ - ۱۳۱۸ (۲۰۱۳).

۶۹. بنهامو، پ.-ی. و همکاران تحويل انسولین با حلقة بسته در بزرگسالان مبتلا به دیابت نوع ۱ در شرایط واقعی: یک کارآزمایی منقاداع تصادفی کنترل شده چند مرکزی ۱۲ هفته ای با بر جسب بازنیست دیگ سلامت‌ا..(2019) e17-e25
۷۰. چاوادا، آر.، قوش، ن.، ساندرا درورا، آی.، مالی، ام. و ون هال، تأسیس یک AUC توسط E5-۲۵ آستانه نفووتکسیسیتی گامی به سوی دوز و انکوماسین فردی برای باکتریئی استافیلوکوکوس اورئوس مقاوم به متی سیلین است. خصص میکروب. عوامل شیمی درمانی. ۱۶، (۰۲۵۳۵-۰۲۵۳۵).
۷۱. هنینگ، س.، هولتهاوسن، ف. و استاتز، س. ای. مقایسه روش های تنظیم دوز برای توبرامایسین یک بار در روز در بیماران کودک و نوجوان مبتلا به فیبروز کیستیک. کلینیک. فارماکوکینتیک. ۵۴، ۴۰-۴۹. (۲۰۱۵).
۷۲. دانسیریکول، سی.، موریس، آر.جی.، تنت، اس.ای. و دافول، اس.بی. رویکرد بیزی برای مدل سازی فارماکوکینتیک جمعیتی سیروولیموس. مجله‌نشک بالینی بریتانیا (Br. J. Clin. Pharmacol) ۲۰۱۵، ۳۴-۳۵.
۷۳. لان، دی. جی، بست، آن.، توماس، ای.، ویکفیلد، جی. و اشپیگل هالتز، دی. تحلیل بیزی مدل های PK/PD جمعیتی: مفاهیم کلی و نرم افزار. مجله فارماکوکینت. فارماکوبدین. ۲۹، ۲۷-۳۰. (۲۰۰۲).
۷۴. هاچینسون، ل. و همکاران مدل ها و ماشین ها: چگونه یادگیری عمیق، داروشناسی Pharmacomet. System. Pharmacol. ۱۳۱، ۸CPT ۱۳۴-۱۳۱. (۲۰۱۹).
۷۵. ماکریداکیس، س.، آسیلیوتوس، ای. و آسیماکوبولوس، و. رقابت M4: نتایج یافته ها، نتیجه گیری و مسیر پیش رو پیش بینی بین المللی /۲۳۴، ۸-۸-۸. (۲۰۱۸).
- در زمینه آکوستیک، گفتار و پردازش سیگنال، کیوتو، ۲۵-۳۰ مارس، ۸۶۲۸-۸۶۲۴. (2012) IEEE پیشرفت ها در بهینه سازی شبکه های بازگشتی. کنفرانس بین المللی 60. Bengio, Y., Boulanger-Lewandowski, N. & Pascanu, R.
۶۵. هوخرابیت، س. و اشمیده‌وبر، ج. حافظه کوتاه مدت بلندمدت. محاسبات عصبی. ۱۷۸-۱۷۳۵ (۱۹۹۷).
۶۶. کودفلو، آی.، بنگو، وای. و کوروبل، ای. یادگیری عمیق (نتشارات MIT، کمبریج. MA. ۲۰۱۶) ><http://www.deeplearningbook.org>
۶۷. چانگ، جی.، گولسهره، سی.، چو، کی. و بنگو، وای. ارزیابی تجربی شبکه های بیزی بازگشتی دروازه دار در مدل سازی توالی. کارگاه آموزشی یادگیری عمیق در NIPS، مونترال، ۸ تا ۱۳ دسامبر (2014).
۶۸. ریو، جی. وای.، کیم، اچ. یو و لی، اس. وای. یادگیری عمیق پیش بینی تداخلات دارو و غذارا بهبود می بخشد. مجموعه مقالات علمی، آکادمی ملن علوم، ۱۱۵، ۰۱۸-۰۱۷. (۲۰۱۸) E4304-E4311
۶۹. Hammann, F., Gutmann, H., Vogt, N., Helma, C. و Drewe, ج. پیش بینی عوارض جانبی داروها با استفاده از مدل سازی درخت تصمیم گیری. کلینیک. فارماکول. درمان. ۵۲-۵۹. (۲۰۱۰).
۷۰. لیکستر، ام.س و سوئی، ای. پیش بینی بهبود یافته ای تورساد دو پوینت های ناشی از دارو از طریق شبیه سازی دینامیک و الگوریتم های یادگیری ماشین. کلینیک. فارماکول. درمان. ۳۷۹-۳۷۱. (۲۰۱۶).
۷۱. دانهاور، آی. و همکاران پیش بینی زودهنگام بهبود یافته هیپریلیروبینیم نوزادی مرتبط با علیعیم بالینی با یادگیری ماشین. اطفال. پژوهش. ۱۲۳-۱۲۰. (۲۰۱۹).
۷۲. گاودا، ای. و همکاران شخصی سازی مدیریت دارویی کم خونی با استفاده از یادگیری تقویتی. شبکه های عصبی. ۸۲۶-۸۳۴. (۲۰۰۵).